Cyfrowe narzędzia w przekładoznawstwie

ALEKSANDRA RYKOWSKA

ALEKSANDRA.RYKOWSKA@DOCTORAL.UJ.EDU.PL

Co to jest stylometria?

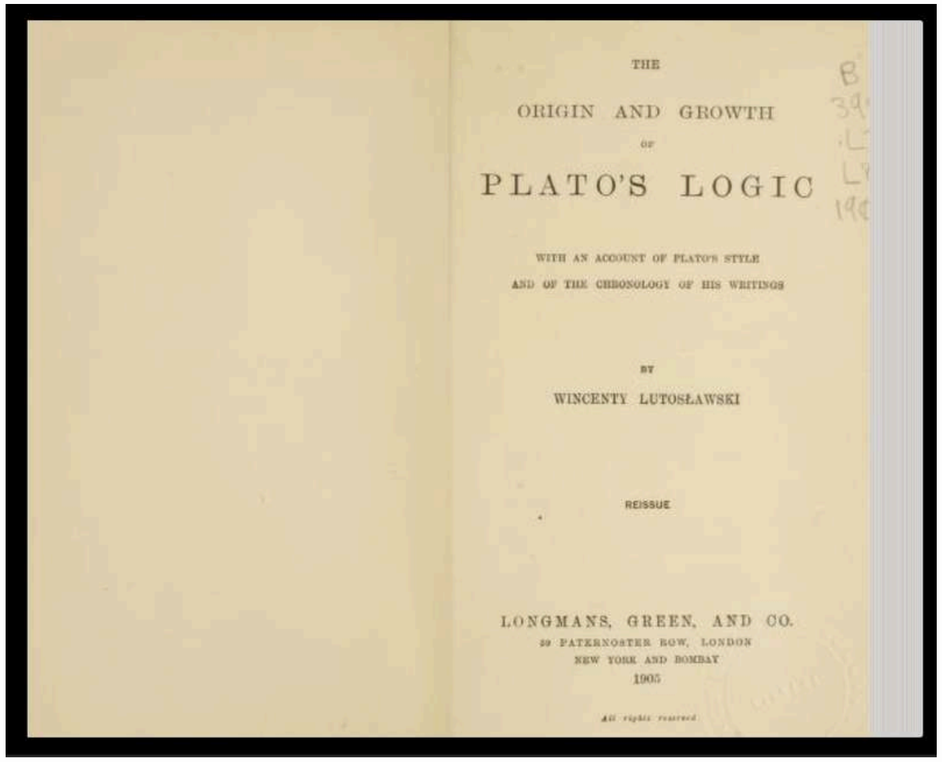
Sposób badania tekstów, w których **liczymy wszelkie jednostki językowe, które jesteśmy w stanie policzyć**

Metoda ilościowej analizy tekstów

Czerpanie wiedzy niekoniecznie bezpośrednio z tekstów, a raczej z **obserwacji relacji między tekstami**

Metoda obserwacji **podobieństw i różnic** między tekstami

Trochę historii...



THE

ORIGIN AND GROWTH

OF

PLATO'S LOGIC

WITH AN ACCOUNT OF PLATO'S STYLE

AND OF THE CHRONOLOGY OF HIS WRITINGS

BY

WINCENTY LUTOSŁAWSKI

REISSUE

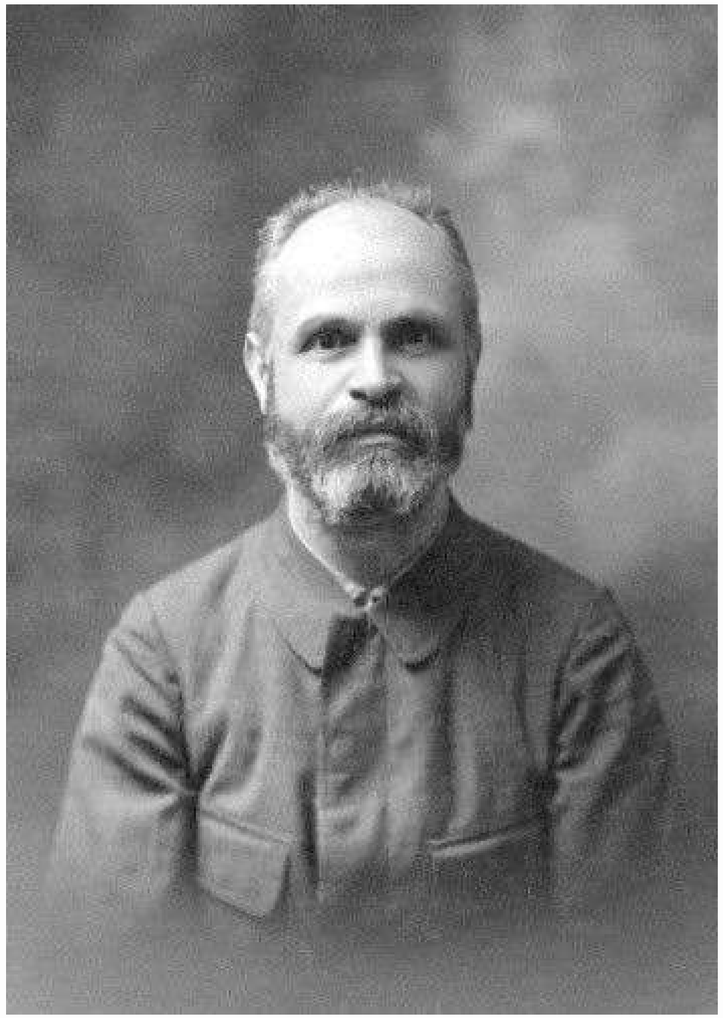
LONGMANS, GREEN, AND CO.

39 PATERNOSTER ROW, LONDON

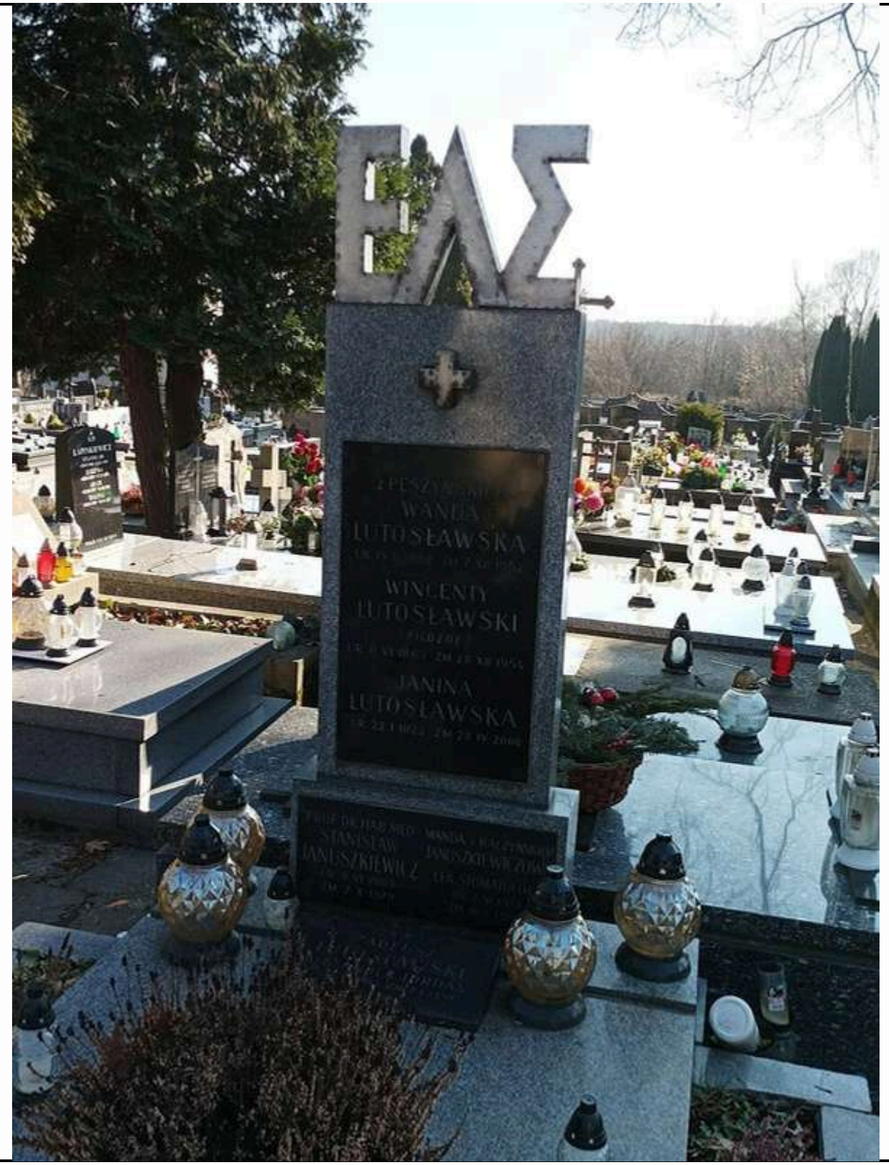
NEW YORK AND BOMBAY

1905

All rights reserved



Trochę historii...



Distant reading (F. Moretti)

Wyjście „poza” (pojedynczy) tekst

Badanie „wszystkich” a nie tylko „reprezentatywnych” tekstów

Pozyskiwanie i analiza danych z bardzo wielu, różnych tekstów

Jeśli w ciągu 2 dni jesteśmy w stanie przeczytać 1 książkę, to przez 50 lat przeczytamy tylko 9125 książek

Distant reading (F. Moretti)

Wyjście „poza” (pojedynczy) tekst

Badanie „wszystkich” a nie tylko „reprezentatywnych” tekstów

Pozyskiwanie i analiza danych z bardzo wielu, różnych tekstów

Jeśli w ciągu 2 dni jesteśmy w stanie przeczytać 1 książkę, to przez 50 lat przeczytamy tylko 9125 książek

W Polsce co roku wydawanych jest 3000-4000 nowych książek.

Jak więc czytać, żeby nie czytać?

Jak więc czytać, żeby nie czytać? Stylometrycznie

Jak więc czytać, żeby nie czytać? Stylometrycznie

- Wystarczy policzyć wartości najczęściej występujących słów, żeby wykryć autorstwo tekstu



Jest prawdą powszechnie mało znaną, że w większości rozważań nad dziełami literackimi **zachowujemy się tak, jakby jednej trzeciej, dwóch piątych, połowy materiału – w ogóle nie było**. A tymczasem ta jedna trzecia, dwie piąte czy połowa materiału to odpowiednio dwadzieścia, trzydzieści i pięćdziesiąt najczęściej występujących słów. Co ciekawe, **są to zwykle te same słowa niezależnie od powieści czy autora: zaimki osobowe, czasowniki posiłkowe, parę przysłówków, spójników, przedimków...** Wszystkie one spełniają więcej niż jedną funkcję gramatyczną i zwykle plasują się – w dodatku na mniej więcej tej samej pozycji – wśród najczęstszych słów każdej powieści (Burrows 1987: 1)

The basic assumptions behind stylometric methods are that the **style is, to a large extent, transmitted by frequent, systematic elements of language**, **which are unconsciously applied**, with authors not controlling their use of these less meaning-making units, which in turn **allows for examining the frequency distributions of these features and combining them into authorial profiles**, that can be compared by means of traditional statistical methods as well as contemporary machine learning algorithms (Byszuk 2024).

No ale jak to działa?

1. Bag-of-words

2. Lista frekwencyjna jakichś jednostek (np. słów)

3. Zamiana wartości liczbowych na wektory

4. Analiza statystyczna danych

Bag-of-words

Nie chodzi tutaj — u kaduka! — o herb ani o szeregi przodków podgolonych, z sarmackimi wąsami i przy karabelach — ani wydekoltowane prababki w fiokach. Ojciec i matka — otóż i cały rodowód, jak to jest u nas, w dziejach nowoczesnych ludzi bez wczoraj. Z konieczności wzmianka o jednym dziadku, z musu notatka o jednym jedynym pradziadku. Chcemy uszanować nasyconą do pełna duchem i upodobaniem semickim awersję ludzi nowoczesnych do obciążania sobie pamięci wiadomościami, w którym kościele czy na jakim cmentarzu dany dziadek spoczywa.

Bag-of-words

Nie chodzi tutaj — u kaduka! — o herb ani o szeregi przodków podgolonych, z sarmackimi wąsami i przy karabelach — ani wydekoltowane prababki w fiokach. Ojciec i matka — otóż i cały rodowód, jak to jest u nas, w dziejach nowoczesnych ludzi bez wczoraj. Z konieczności wzmianka o jednym dziadku, z musu notatka o jednym jedynym pradziadku. Chcemy uszanować nasyconą do pełna duchem i upodobaniem semickim awersję ludzi nowoczesnych do obciążania sobie pamięci wiadomościami, w którym kościele czy na jakim cmentarzu dany dziadek spoczywa.

Stefan Żeromski, *Przedwiośnie*

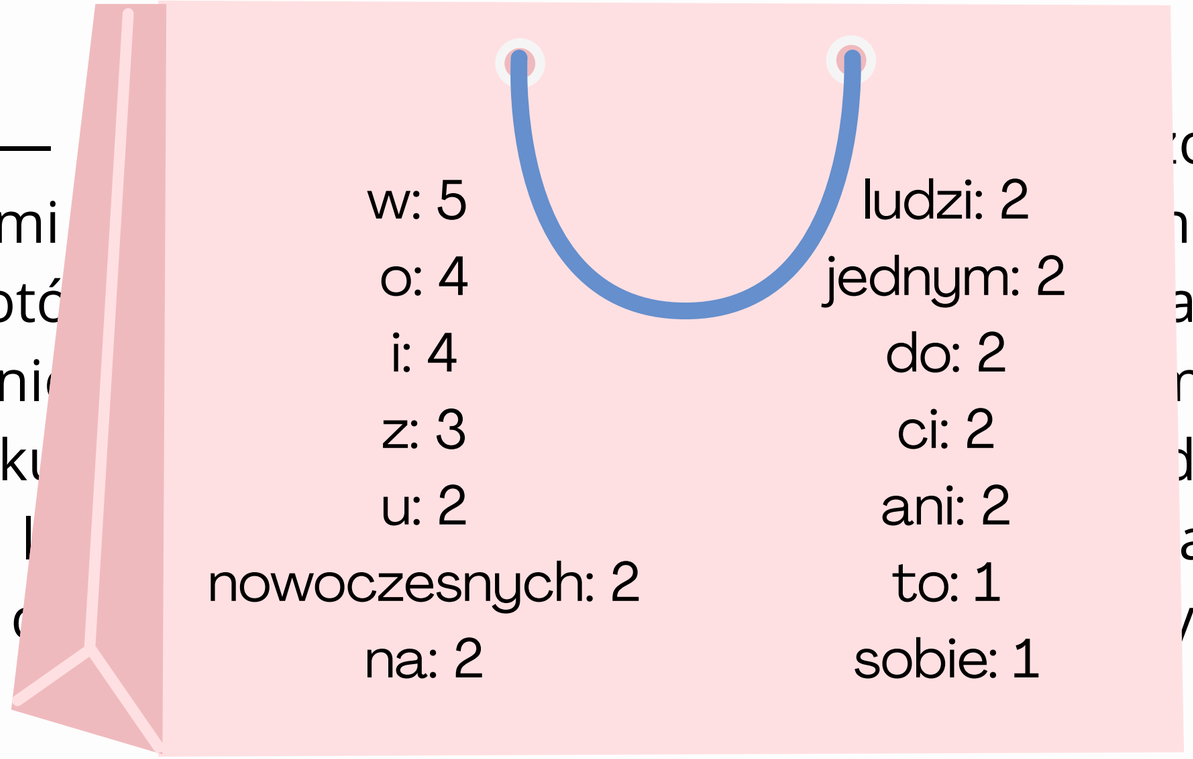
Bag-of-words

Nie chodzi tutaj — …zodków podgolonych, z sarmackimi wąsami …ne prababki w fiokach. Ojciec i matka — otó… …ach nowoczesnych ludzi bez wczoraj. Z koni… …musu notatka o jednym jedynym pradziadku… …duchem i upodobaniem semickim awersję l… …amięci wiadomościami, w którym kościele … …wa.

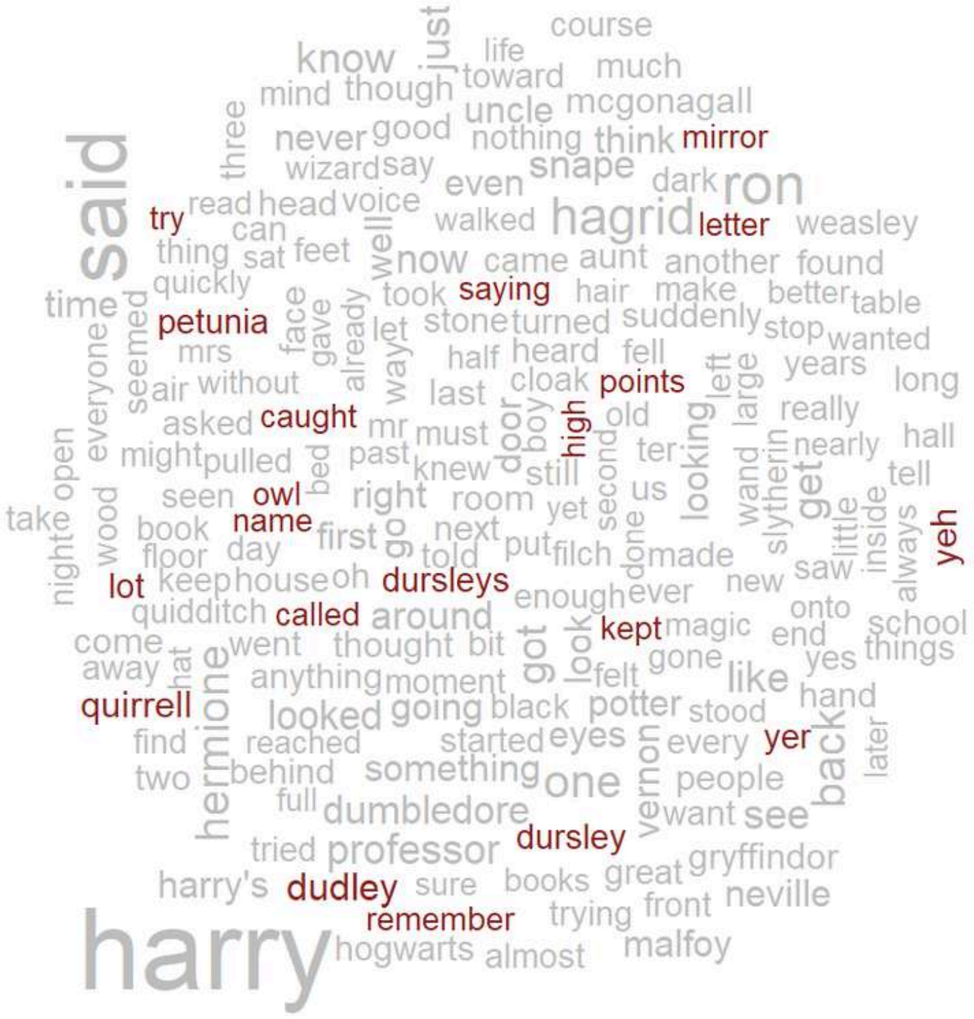


Bag-of-words

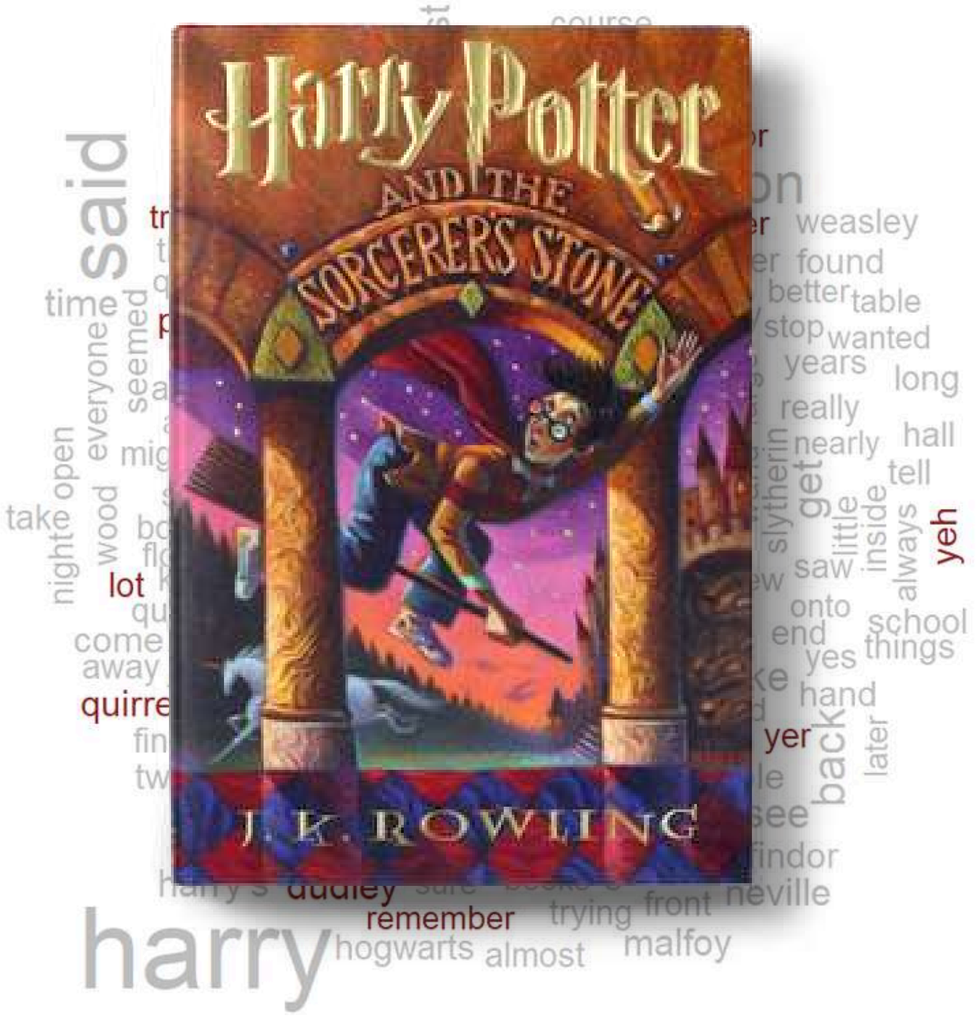
Nie chodzi tutaj — …zodków podgolonych, z sarmackimi wąsami …ne prababki w fiokach. Ojciec i matka — otó… …ach nowoczesnych ludzi bez wczoraj. Z koni… …nusu notatka o jednym jedynym pradziadku… …duchem i upodobaniem semickim awersję l… …amięci wiadomościami, w którym kościele … …wa.



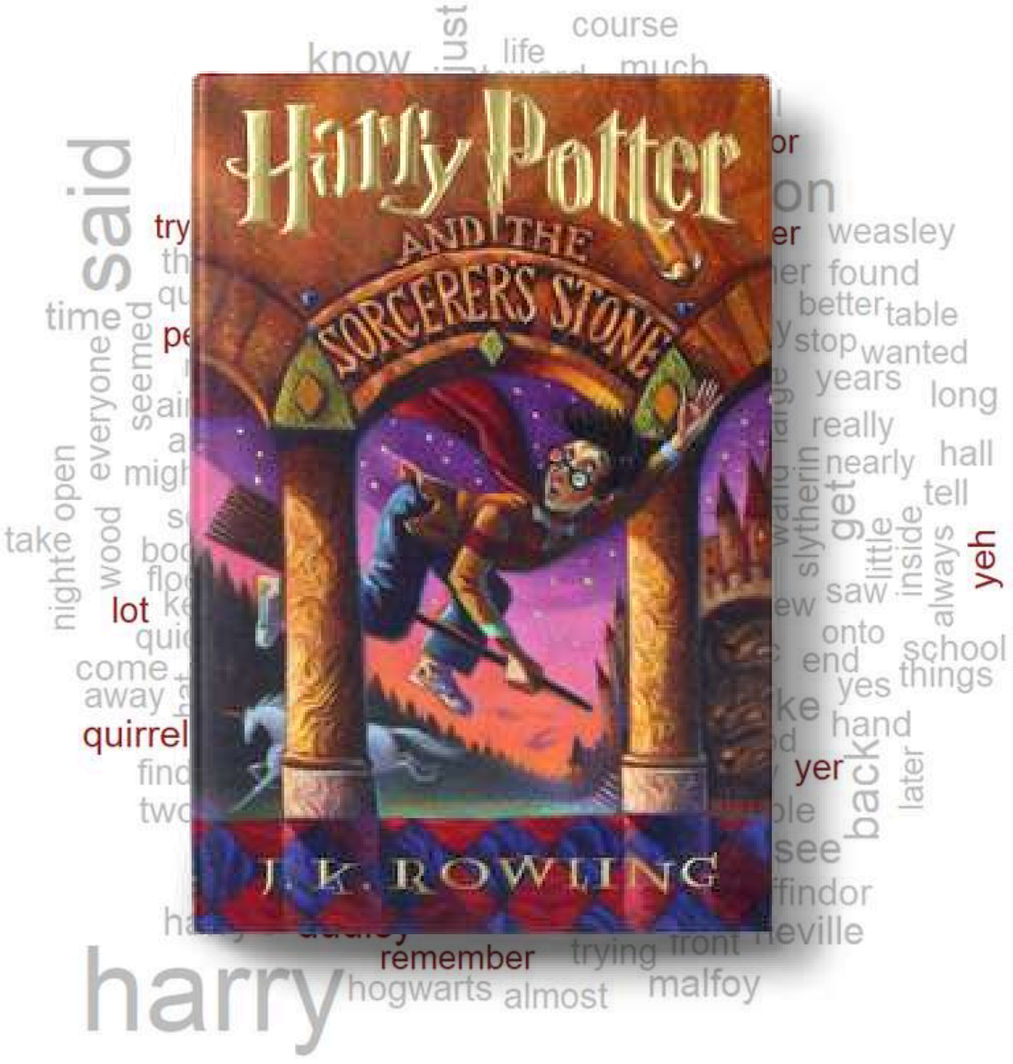
Czy możemy z tej metody coś wywnioskować?



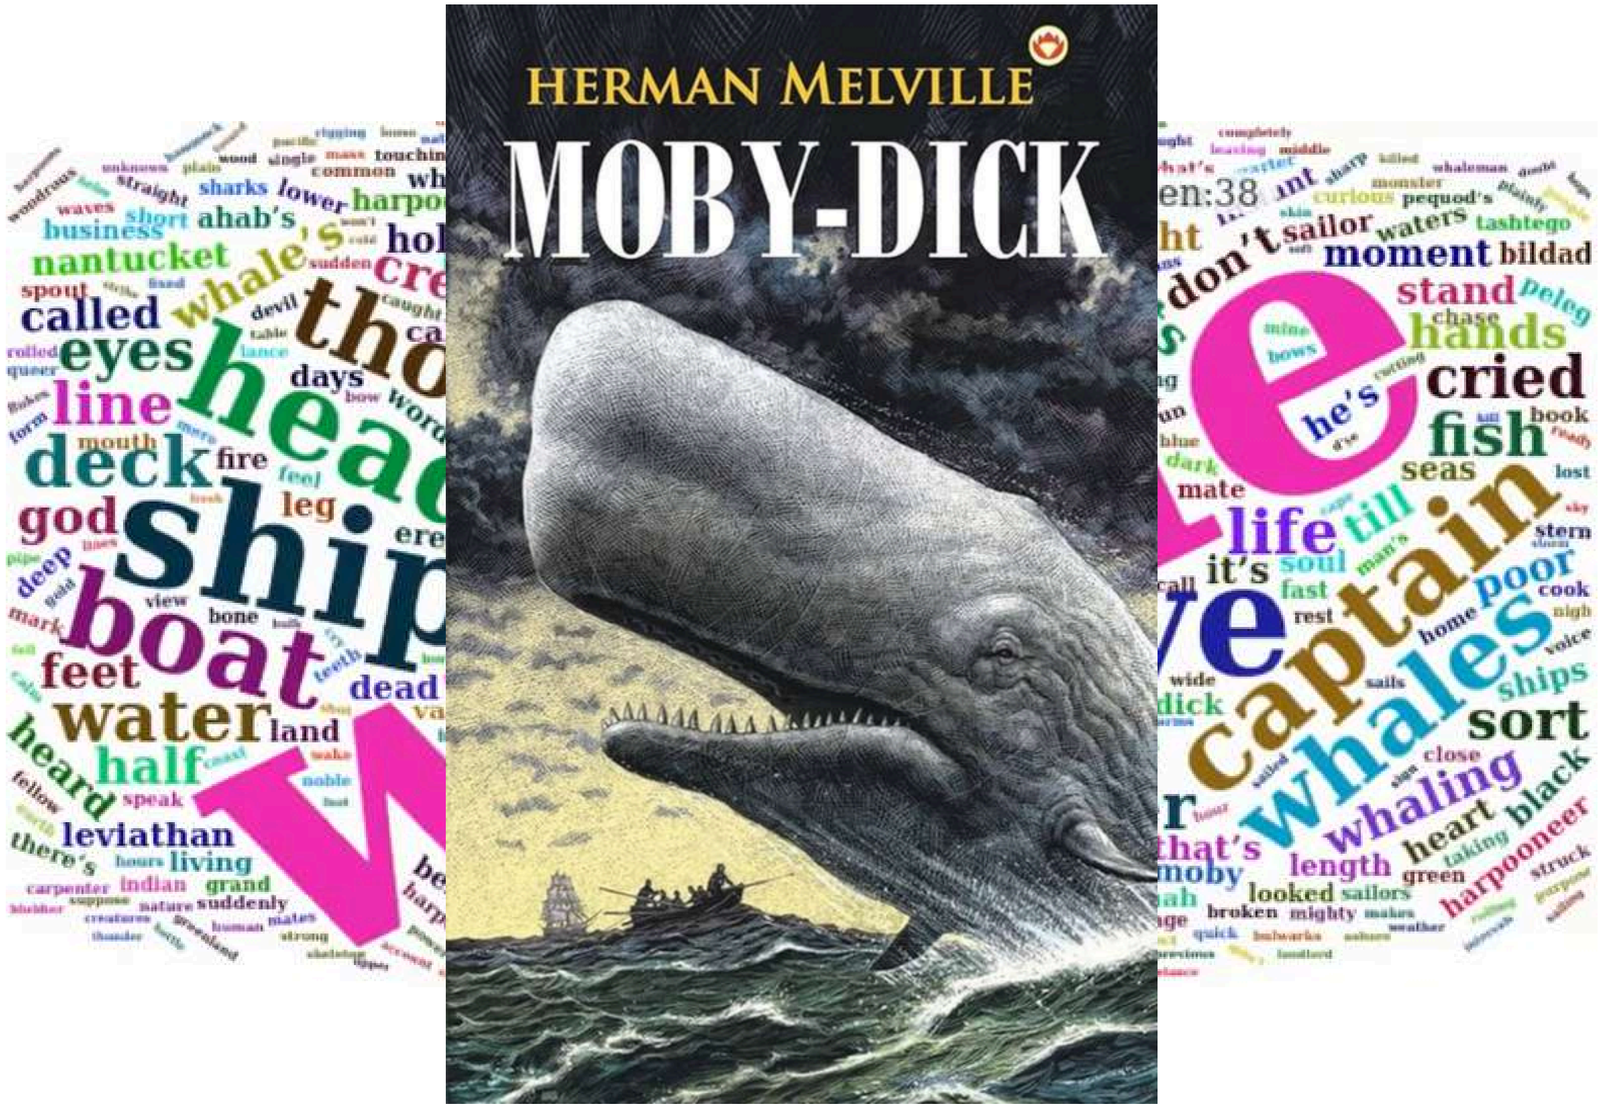
Czy możemy z tej metody coś wywnioskować?




harry
said
ron
hagrid
hermione
dumbledore
professor
dursley
dudley
petunia
dursleys
quirrell
remember
hogwarts
malfoy
neville
gryffindor
mirror
letter
owl
name
caught
called
around
looked
going
kept
saying
yeh
lot
yer
know
think
never
uncle
snape
weasley
harry's
sure
books
great
trying
front
almost
people
something
one
see
want
vernon
potter
black
back
like
get
got
look
felt
eyes
started
reached
behind
full
tried
two
find
away
come
went
thought
bit
anything
moment
quidditch
floor
day
keep
house
oh
enough
ever
new
saw
onto
school
things
magic
end
yes
gone
hand
later
stood
hair
make
better
table
stone
turned
suddenly
stop
wanted
years
long
heard
fell
half
cloak
points
left
large
really
nearly
hall
tell
inside
always
little
slytherin
wand
second
done
made
filch
put
next
go
first
right
room
yet
us
looking
high
door
boy
old
ter
still
knew
past
bed
might
pulled
asked
mr
must
without
air
seemed
everyone
open
take
night
wood
time
quickly
thing
sat
feet
head
voice
walked
came
aunt
another
found
took
saying
stone
let
way
already
gave
face
mrs
can
read
try
wizard
say
even
dark
nothing
mcgonagall
toward
life
course
mind
though
three
just
now
well
hogsmeade
hermione
hagrid
ron
said
harry
professor
lupin
dementors
pettigrew
scabbers
buckbeak
black's
firebolt
crookshanks
trelawney
marge
dumbledore
mcgonagall
rat
rest
map
team
malfoy
dementor
looking
black
wand
reached
whispered
hagrid's
harry's
suddenly
slytherin
behind
along
moment
three
room
one
lupin
sure
want
weasley
knew
felt
voice
need
course
came
done
must
get
professor
looked
going
something
uncle
fred
bed
keep
enough
last
head
went
right
told
door
away
gone
table
night
seen
saw
well
way
set
new
school
feet
sight
take
trying
floor
great
aunt
large
first
little
open
gryffindor
better
quidditch
never
yes
mr
left
hall
people
around
started
inside
thing
neville
george
hear
back
turned
wood
began
dark
heard
without
took
hand
two
still
mind
even
oh
nothing
made
boy
time
year
anything
cloak
good
everyone
snape
match
face
outside
let
next
ter
opened
quickly
siriusfudge
dear
like
tell
air
now
make
look
another
really
staring
percy
vernon
us
hair
class
bit
put
old
end
yet
side
go
gave
best
stan
seemed
sat
ron's
hogwarts
magic
think
hands
might
help
pulled
toward
across
madam
castle
ever
happened
potter
got
robes
forward
thought
much
eyes
know
seemed
say
day
come
can
front
long
stood
hall
people
around
dementors
siriusfudge
quickly
opened
pettigrew
outside
let
next
face
match
black's
best
stan
everyone
snape
scabbers
dear
firebolt
anything
cloak
time
year
began
dark
buckbeak
made
boy
nothing
without
took
heard
hand
still
two
mind
even
oh
make
really
staring
map
dumbledore
mcgonagall
every
enough
last
malfoy
team
rat
head
went
away
rest
table
marge
gone
crookshanks
take
feet
sight
bed
keep
going
uncle
something
fred
looking
dementor
black
wand
reached
whispered
hagrid's
harry's
suddenly
slytherin
behind
along
moment
three
room
one
lupin
sure
want
weasley
knew
felt
voice
need
course
came
done
must
get
professor
looked
night
seen
saw
well
way
set
new
school
feet
sight
take
trying
floor
great
aunt
large
first
little
open
gryffindor
better
quidditch
never
yes
mr
left

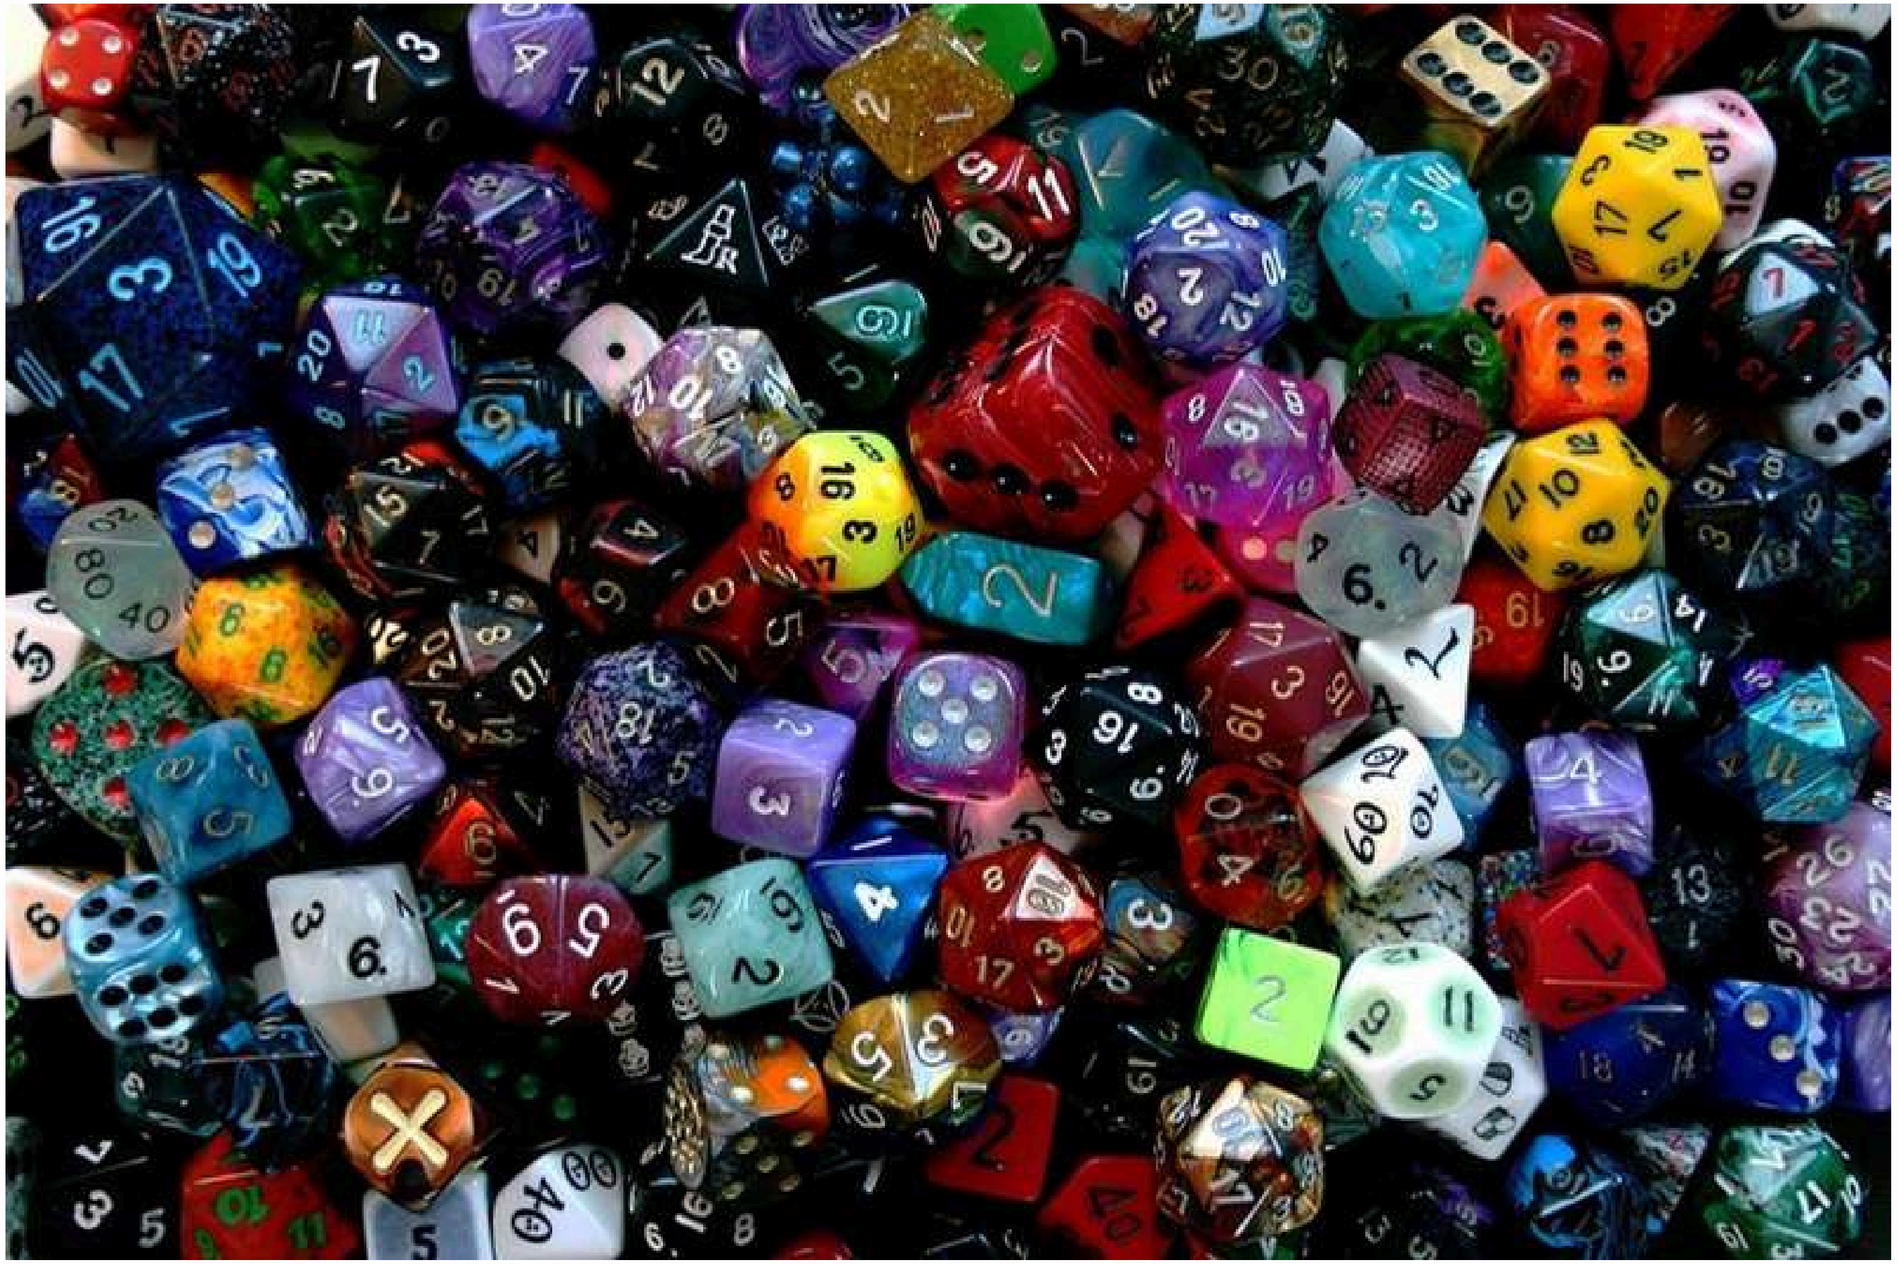

Harry Potter
AND THE SORCERER'S STONE
J.K. ROWLING
harry
said
time
lot
quirrel
yeh
yer
remember
hogwarts
almost
malfoy
trying
front
dementor
scabbers
best
ron
hermione
hagrid
hogsmeade
Harry Potter
AND THE Prisoner of AZKABAN
J.K. ROWLING
SCHOLASTIC
black's
buckbeak
rat
rest
harry
suddenly
slytherin
behind
harry's
moment
three
along
asked


whale
sea
head
ship
boat
time
thousand
round
sperm
captain
ye
whales
white
hand
chapter
gentlemen:38
world
night
boats
crew
whale's
hold
times
harpoon
strange
voyage
sight
don't
sailor
moment
bildad
stand
peleg
hands
cried
fish
poor
life
till
soul
it's
ships
sort
whaling
heart
black
harpooneer
struck
length
found
that's
moby
jonah
looked
sailors
broken
mighty
heads
matter
mind
peculiar
savage
watch
forward
hundred
coming
stranger
ground
running
creature
wind
ship's
death
body
pequod
thee
beneath
harpooneers
reason
english
sound
mast
aloft
true
hard
blood
bed
rope
dead
vast
water
land
feet
deck
god
deep
mark
line
eyes
called
nantucket
spout
cabin
devil
caught
crew
iron
aye
lord
word
days
air
sir
oil
lay
thy
sail
eye
told
pip
sun
tail
set
i'll
flask
live
top
wild
day
arm
dick
boy
craft
wide
rope
bed
hole
vast
land
half
heard
speak
noble
leviathan
there's
living
grand
suddenly
indian
carpenter
hours
nature
mates
human
strong
thunder
greenland
whale
fire
leg
ere
jaw
cut
left
bone
view
ten
fine
pipe
teeth
born
call
fast
rest
home
nigh
voice
cook
stern
lost
seas
mate
dark
blue
king
run
he's
book
ready
chase
mine
bows
curling
sleep
means
house
hear
main
pull
story
pass
lance
table
queer
rolled
form
mouth
mere
feel
fishes
sudden
ivory
broad
short
business
sharks
lower
straight
waves
ahab's
whalemen
morning
common
touching
coffin
thousand
entire
bottom
chance
ocean
light
boat
surface
vessel
seamen
gentlemen
middle
leaning
completely
brought
what's
curious
pequod's
monster
killed
whaleman
waters
tashtego
skin
soft
sharp
plainly
quote
wondrous
unknown
plain
wood
single
mass
natural
mortal
chief
pacific
rigging
boys
hour
quick
bulwarks
ashore
weather
mates
makes
mighty
broken
looked
sailors
green
taking
struck
harpooneer
close
sails
signs
sailed
voice
nigh
home
rest
fast
soul
it's
call
wide
dick
arm
craft
boy
top
wild
day
flask
live
set
i'll
tail
sun
pip
oil
lay
thy
sail
eye
told
dark
blue
king
run
he's
mate
seas
lost
stern


HERMAN MELVILLE
MOBY-DICK

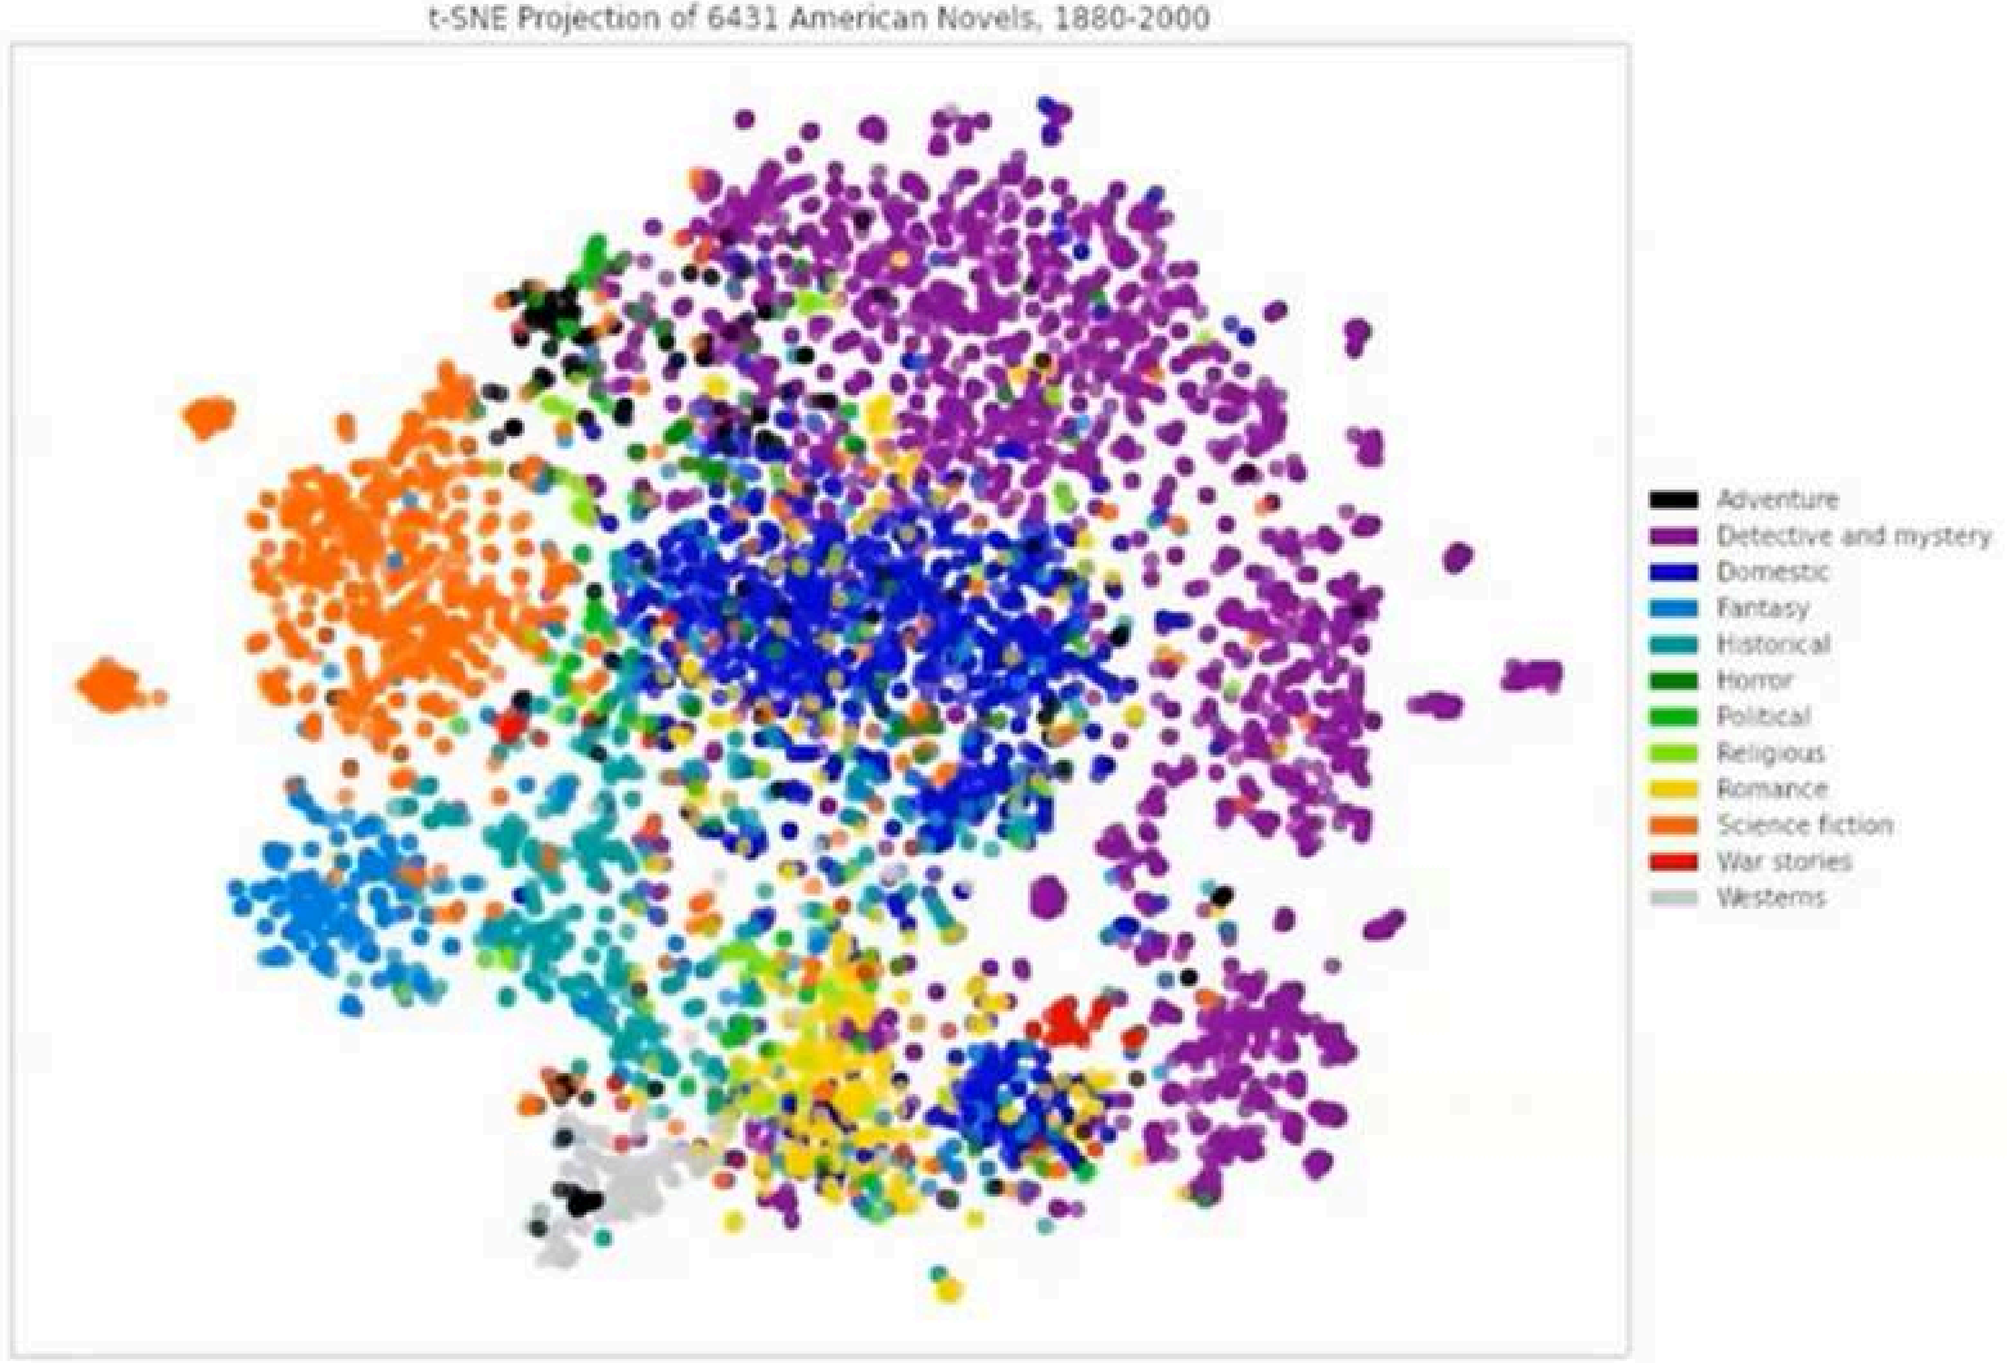
Proxies

- Częstości słów są efektem wyboru konkretnych słów przez danych autorów
- Wybór konkretnych słów przez danych autorów jest efektem działania **sił organizujących tekst**
- Siły organizujące tekst są efektem **warunków społecznych i kulturowych**, w których dany tekst powstaje





Jak wyrzucimy wszystkie te kości, to ułożą się mniej więcej tak....


t-SNE Projection of 6431 American Novels, 1880-2000
Adventure
Detective and mystery
Domestic
Fantasy
Historical
Horror
Political
Religious
Romance
Science fiction
War stories
Westerns

Jak zamienić wartości liczbowe wystąpień najczęstszych słów w miarę podobieństwa tekstów?

- czyli trochę statystyki, ale przystępnej

Wróćmy do Johna Burrowsa i jego delty

$$\Delta = \sum_{i=1}^{n} \frac{|z(x_i) - z(y_i)|}{n}$$

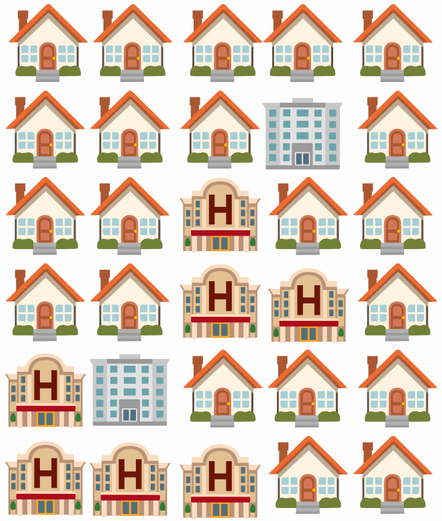


text 1



Δ (T1, T2)

text 2

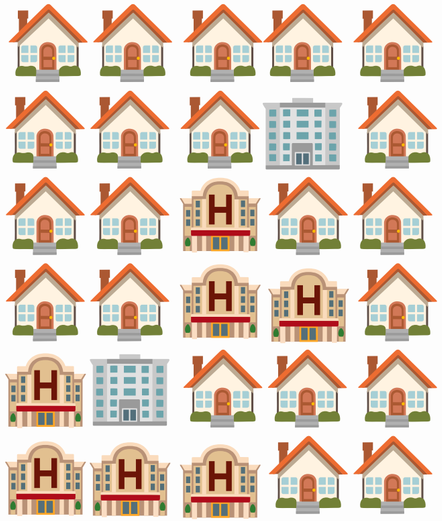


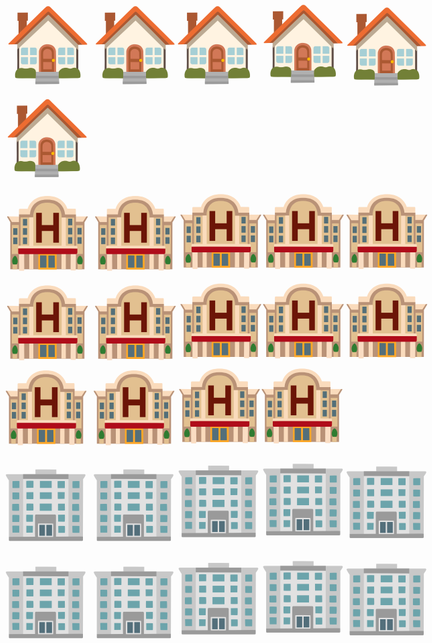
text 1

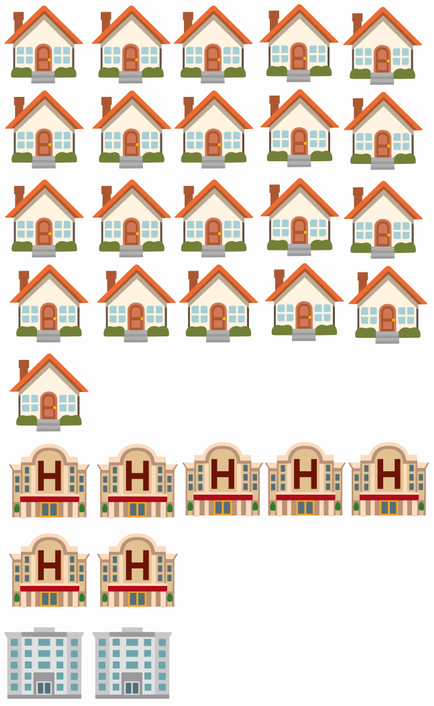


Δ (T1, T2)

text 2





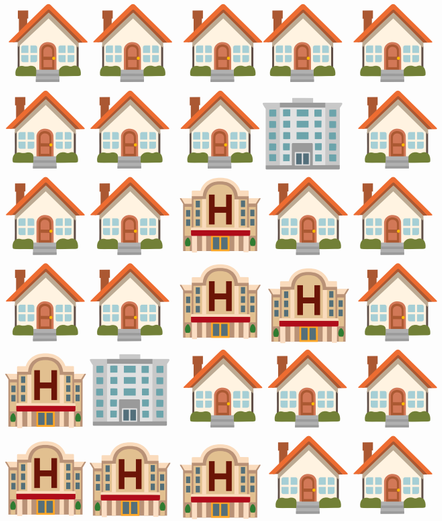


text 1

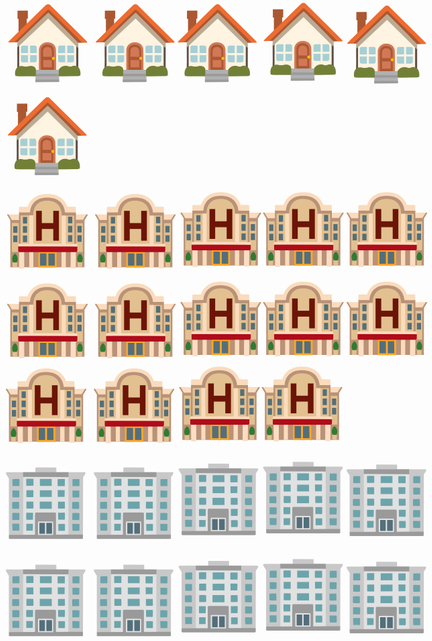


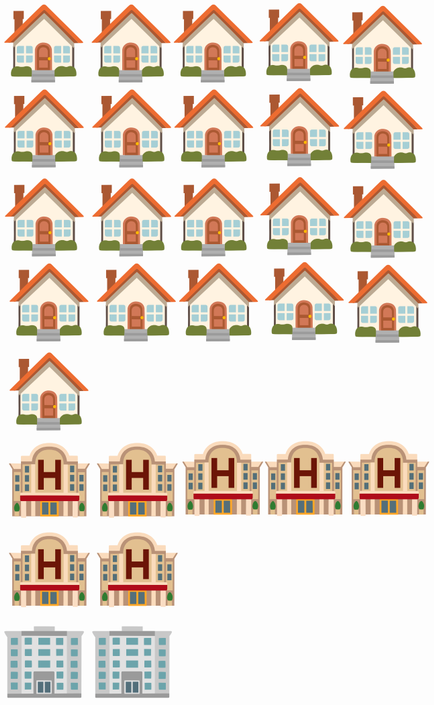
Δ (T1, T2)

text 2



T1(6, 15, 10)





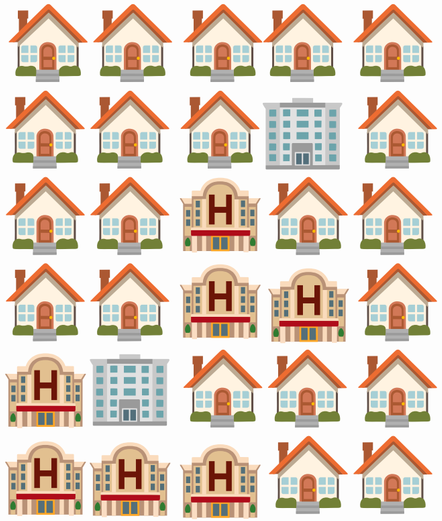
T1(21, 7, 2)

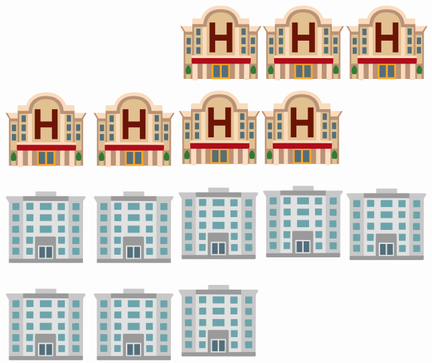
text 1



Δ (T1, T2)

text 2





Δ

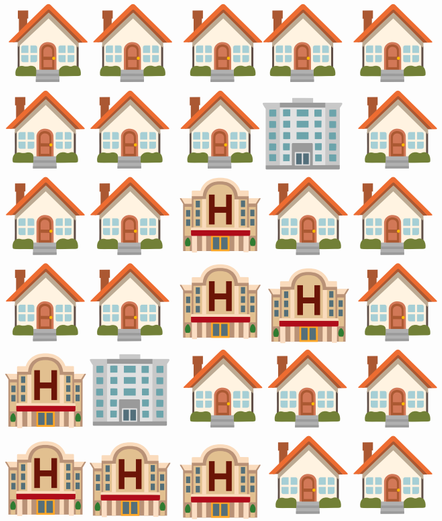


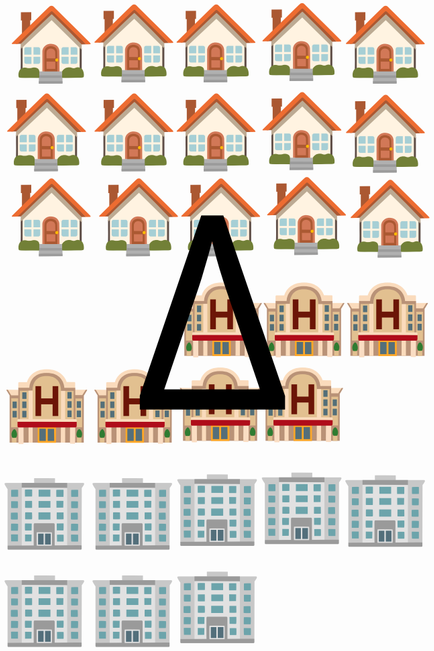
text 1



Δ (T1, T2)

text 2





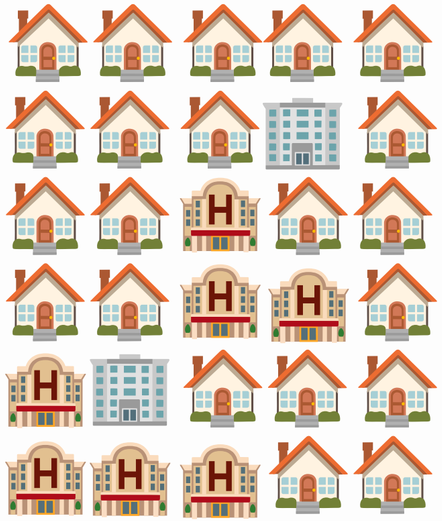
Δ (T1, T2) = (15, 7, 8)

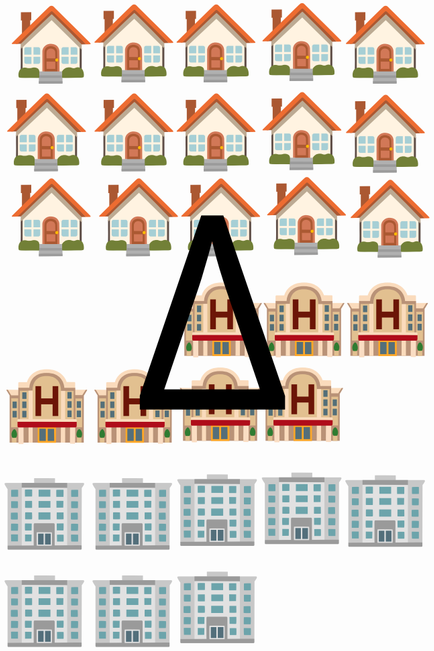
text 1



Δ (T1, T2)

text 2





Δ (T1, T2) = (15, 7, 8)

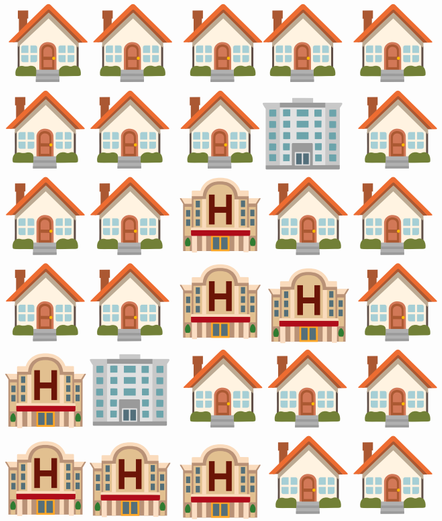
Δ (T1, T2) = 15 + 7 + 8 = 30

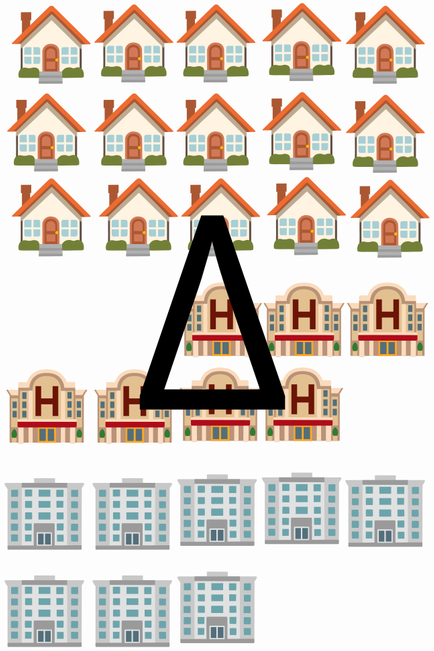
text 1



Δ (T1, T2)

text 2

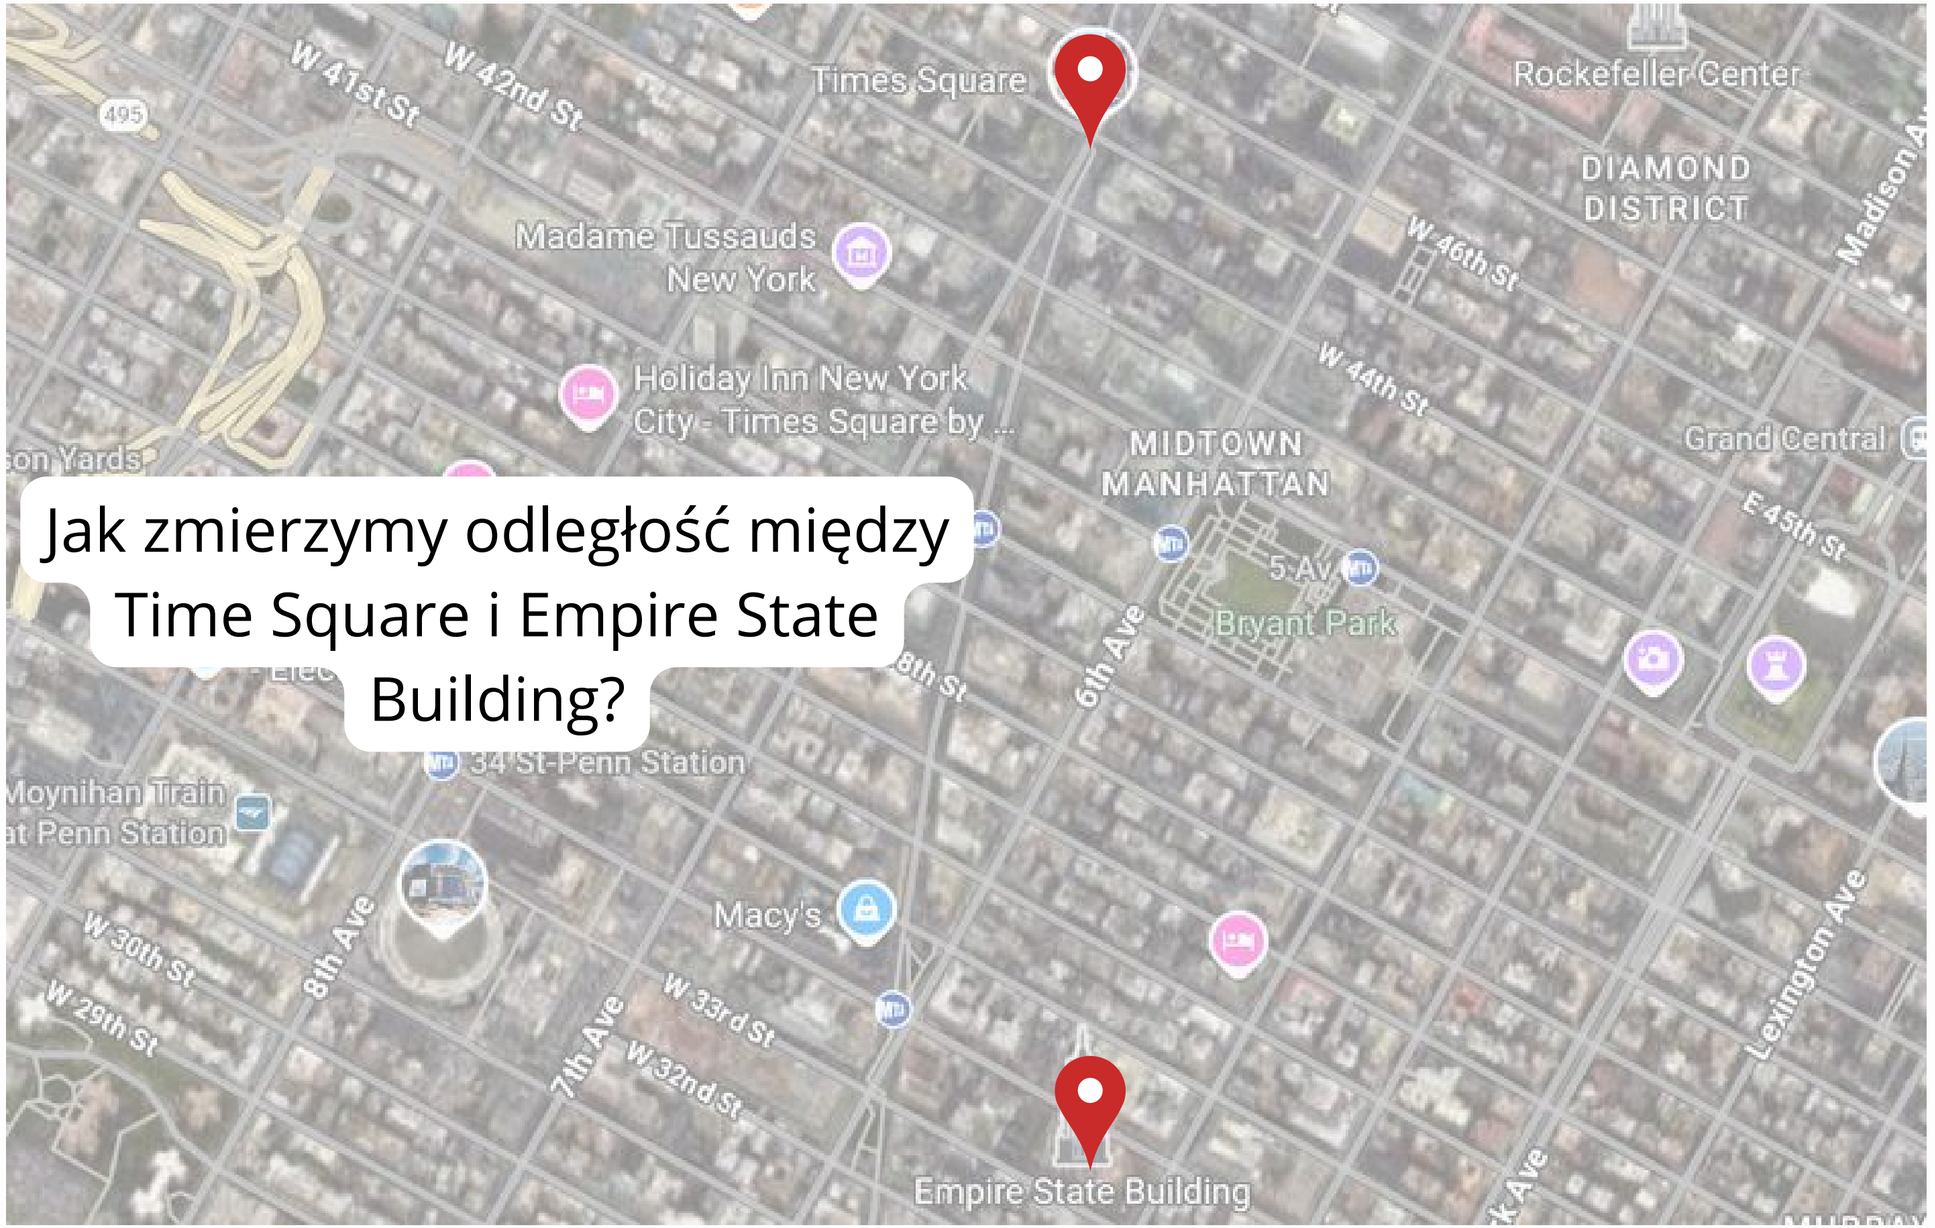


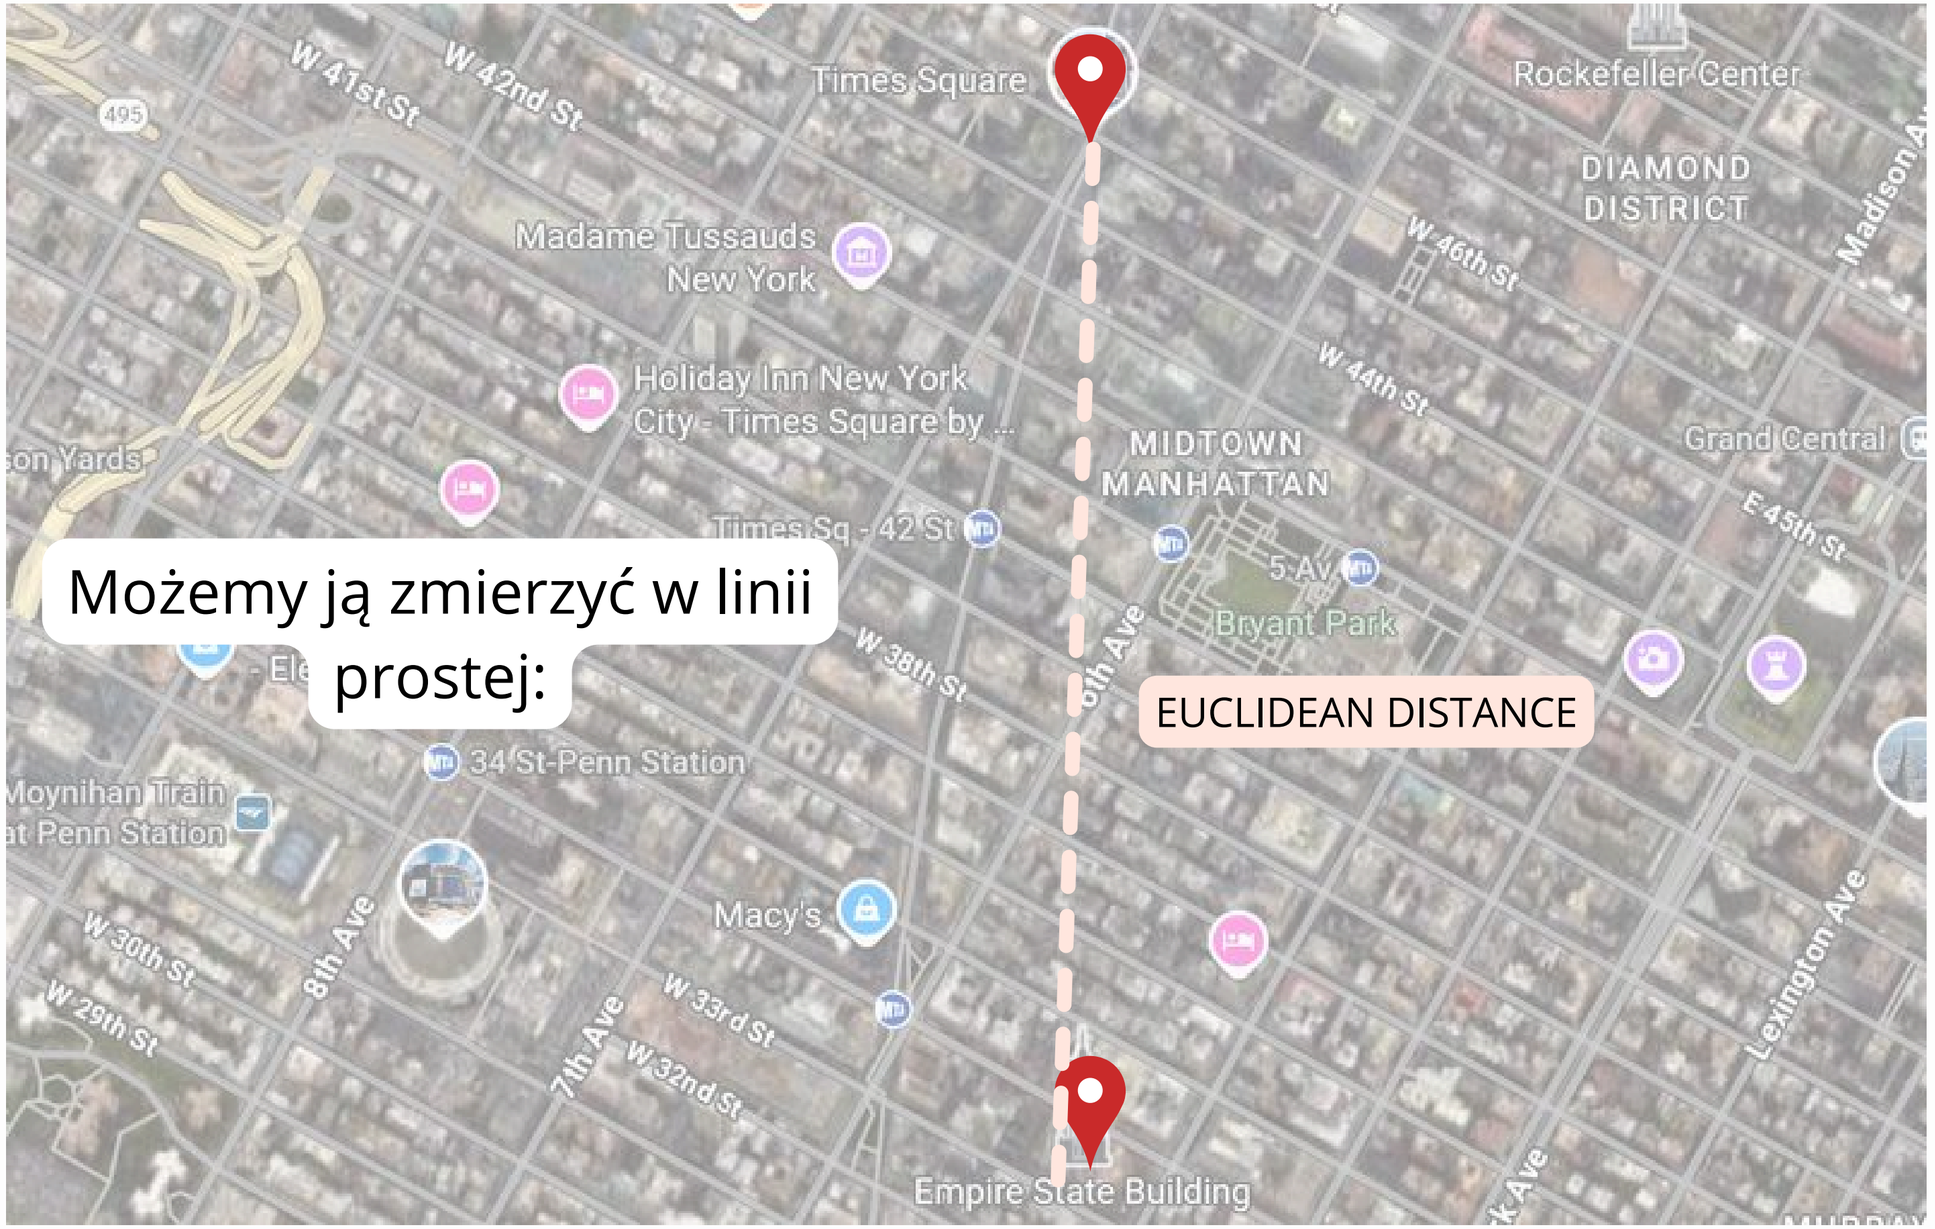


Δ (T1, T2) = (15, 7, 8)

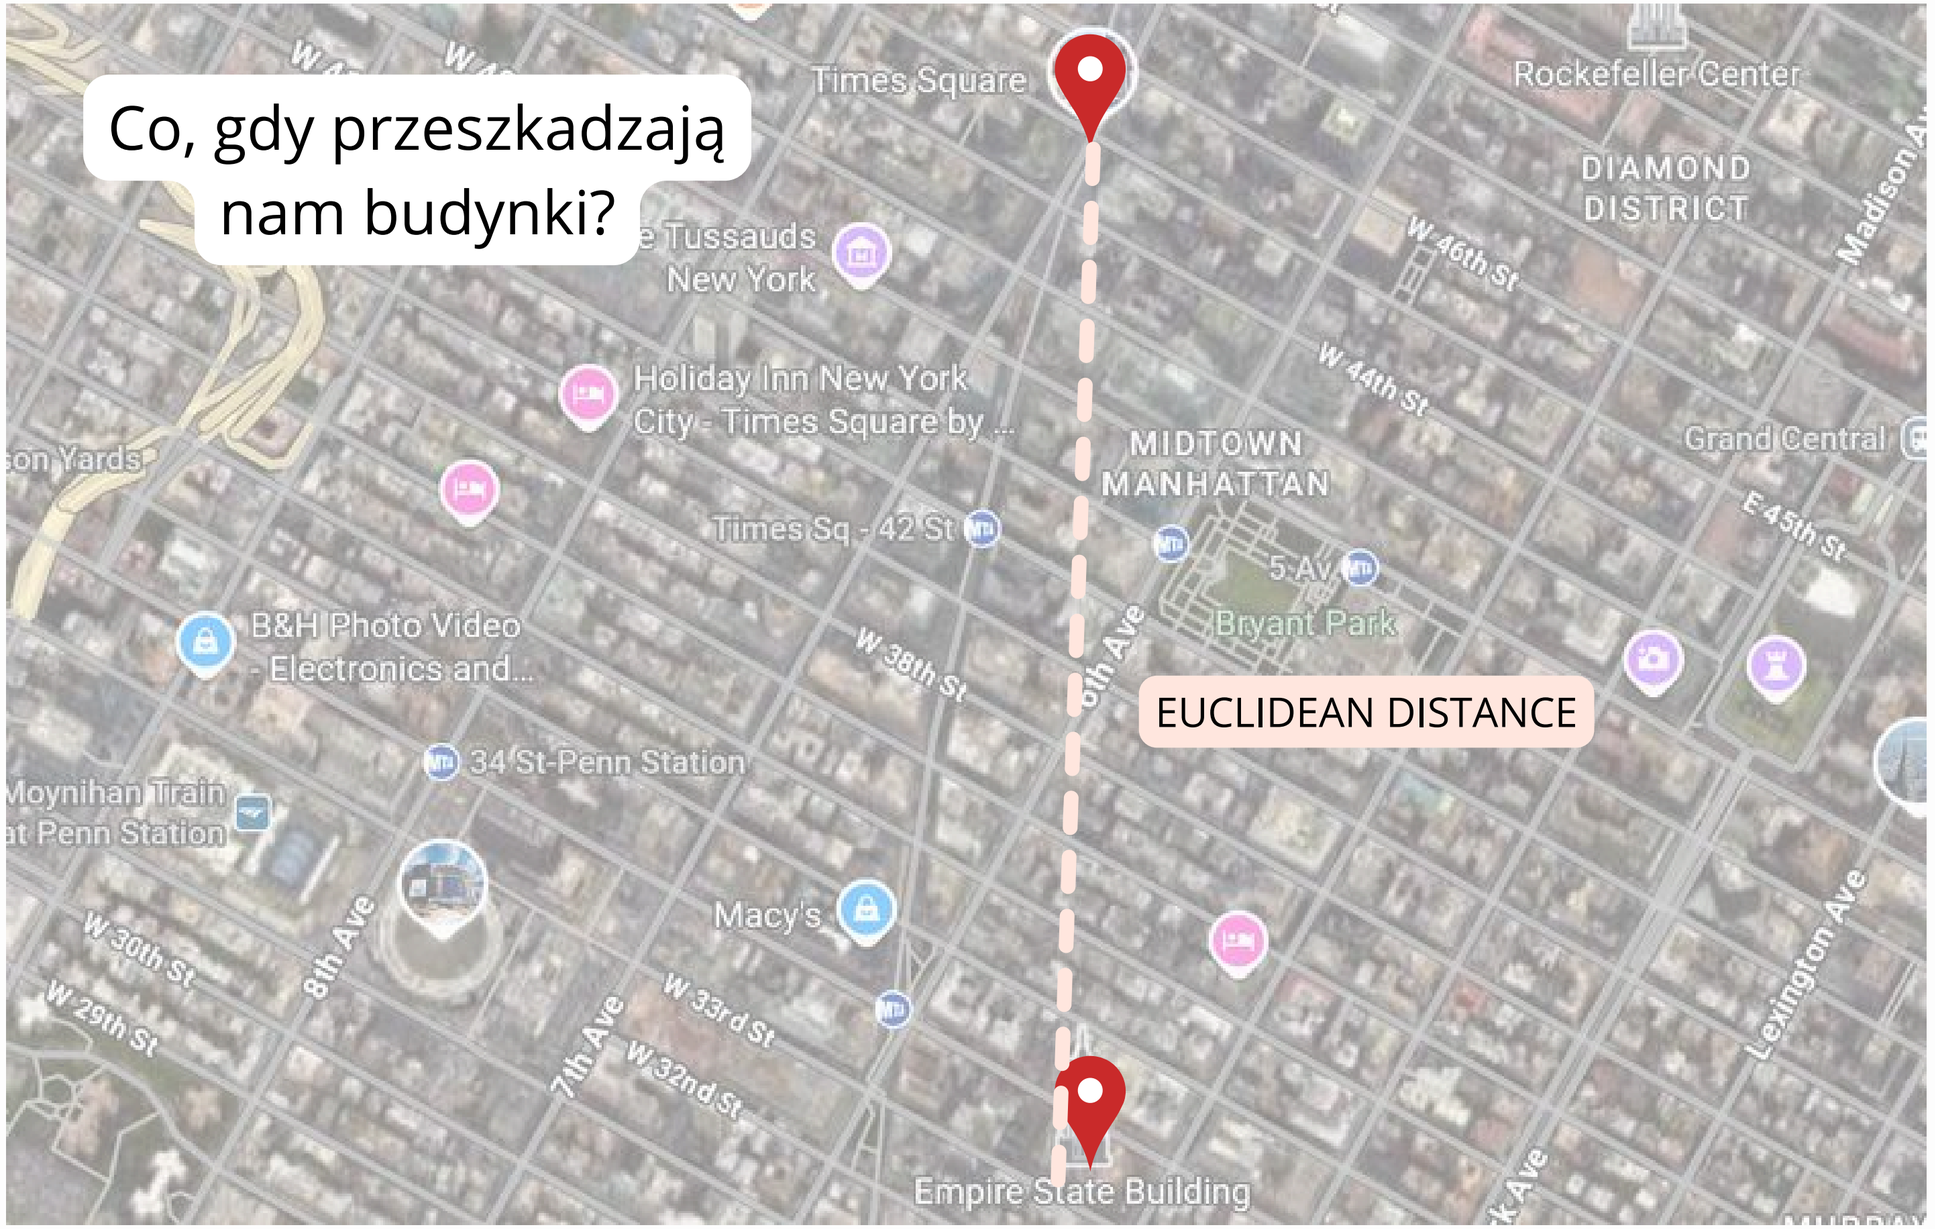
Δ (T1, T2) = 15 + 7 + 8 = 30

tzw. Manhattan distance (city block distance), z małymi poprawkami Burrowsa


Jak zmierzymy odległość między Time Square i Empire State Building?
Times Square
Rockefeller Center
DIAMOND DISTRICT
Madame Tussauds New York
Holiday Inn New York City - Times Square by ...
MIDTOWN MANHATTAN
Grand Central
Bryant Park
5 Av
34 St-Penn Station
Moynihan Train at Penn Station
Macy's
Empire State Building
W 41st St
W 42nd St
W 46th St
W 44th St
E 45th St
6th Ave
8th Ave
7th Ave
W 30th St
W 29th St
W 33rd St
W 32nd St
Lexington Ave
495

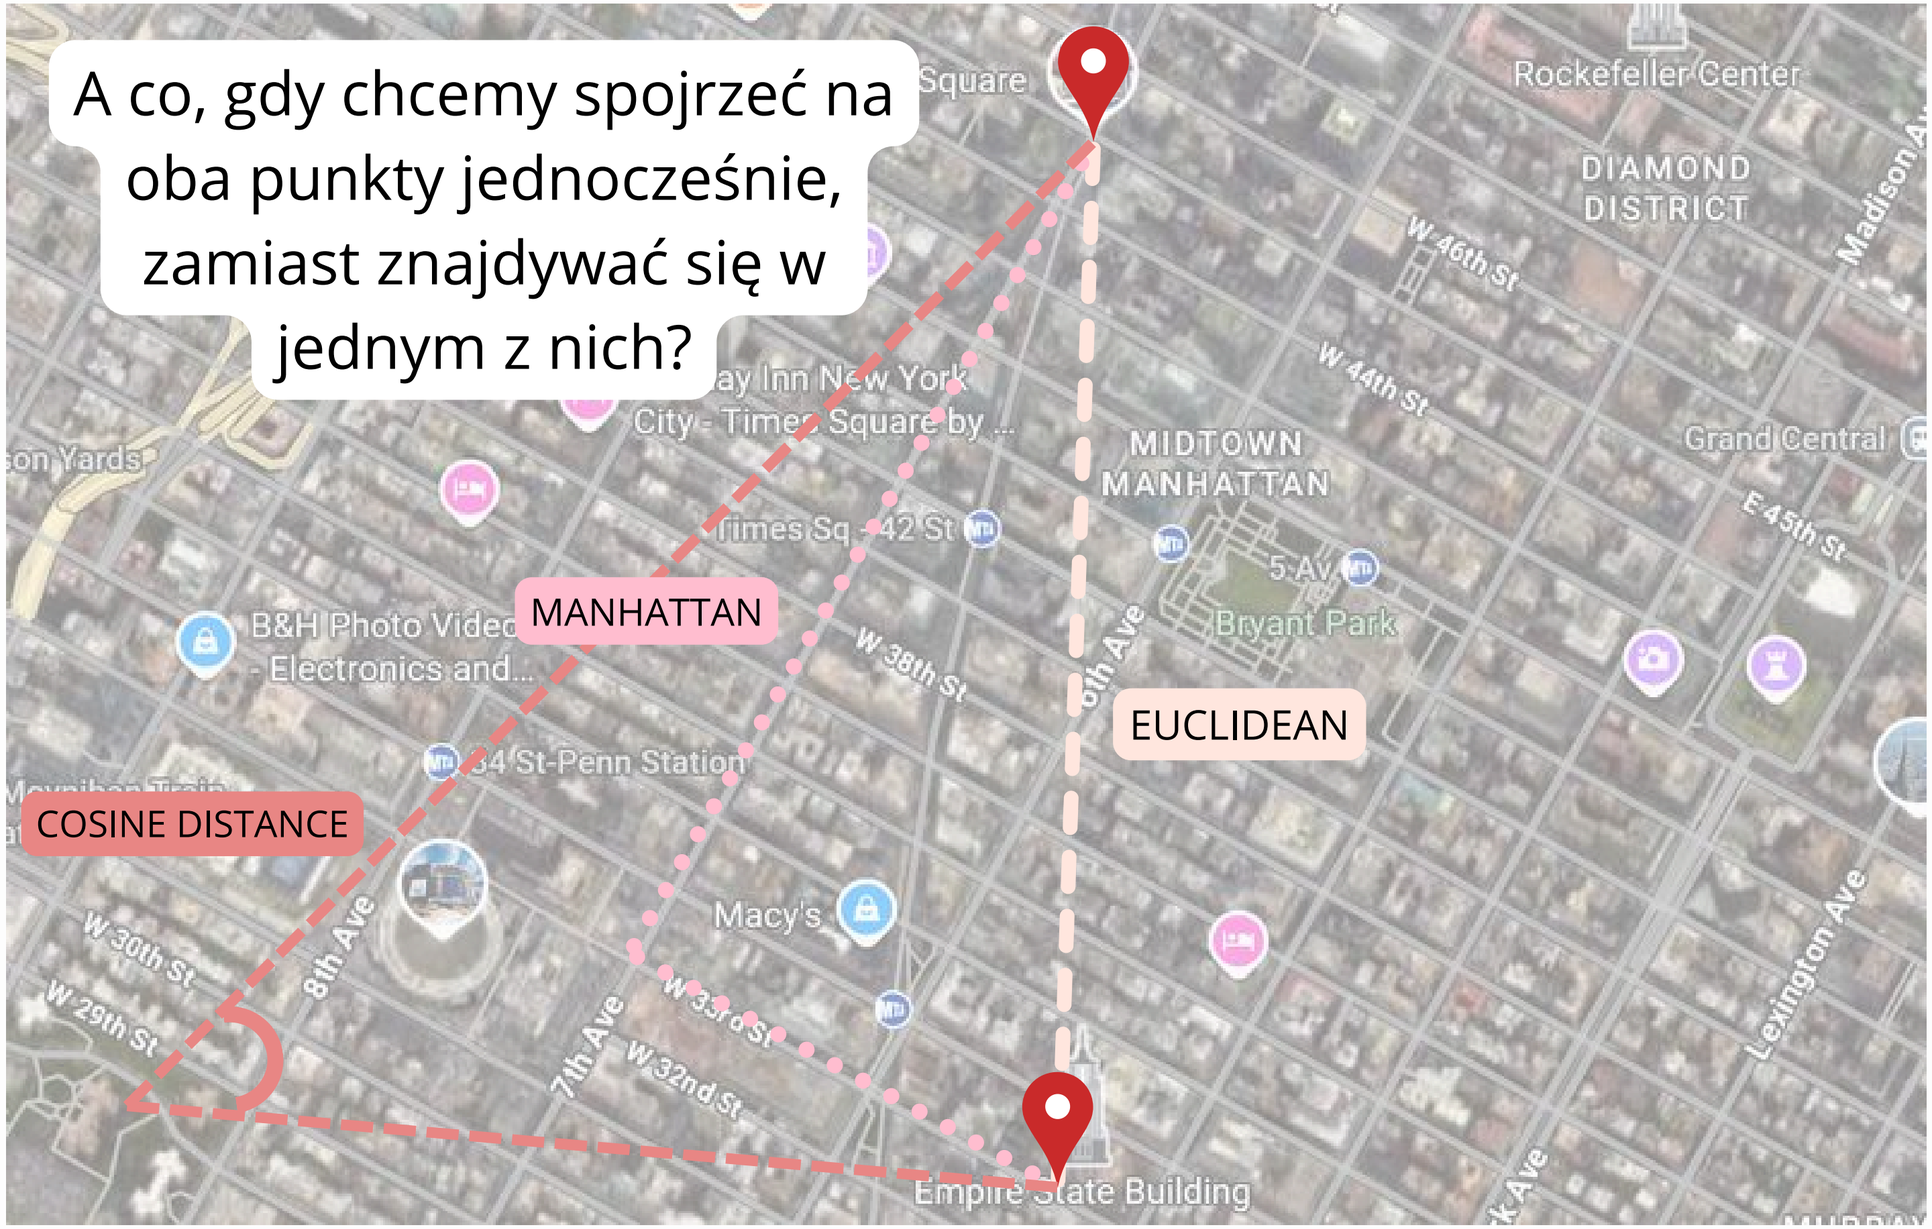

Times Square
Rockefeller Center
DIAMOND DISTRICT
Madame Tussauds New York
Holiday Inn New York City - Times Square by ...
MIDTOWN MANHATTAN
Grand Central
Times Sq - 42 St
5 Av
Bryant Park
34 St-Penn Station
Moynihan Train at Penn Station
Macy's
Empire State Building
W 41st St
W 42nd St
W 46th St
W 44th St
E 45th St
W 38th St
W 30th St
W 29th St
W 33rd St
W 32nd St
8th Ave
7th Ave
6th Ave
Lexington Ave
Madison Ave
495
Możemy ją zmierzyć w linii prostej:
EUCLIDEAN DISTANCE


$\sqrt{(x_2-x_1)^2 + (y_2-y_1)^2}$
Times Square
W 41st St
W 42nd St
Madame Tussauds New York
Holiday Inn New York City - Times Square by ...
W 46th St
W 44th St
MIDTOWN MANHATTAN
Grand Central
E 45th St
Times Sq - 42 St
5 Av
Bryant Park
6th Ave
W 38th St
Możemy ją zmierzyć w linii prostej:
EUCLIDEAN DISTANCE
34 St-Penn Station
Moynihan Train
at Penn Station
Macy's
8th Ave
W 30th St
W 29th St
7th Ave
W 33rd St
W 32nd St
Lexington Ave
Empire State Building


Co, gdy przeszkadzają nam budynki?
Times Square
Rockefeller Center
DIAMOND DISTRICT
Madison Ave
W 46th St
W 44th St
Tussauds New York
Holiday Inn New York City - Times Square by ...
MIDTOWN MANHATTAN
Grand Central
E 45th St
Times Sq - 42 St
5 Av
Bryant Park
B&H Photo Video - Electronics and...
W 38th St
6th Ave
EUCLIDEAN DISTANCE
34 St-Penn Station
Moynihan Train at Penn Station
Macy's
W 30th St
W 29th St
8th Ave
W 33rd St
7th Ave
W 32nd St
Lexington Ave
Empire State Building


Co, gdy przeszkadzają nam budynki?
Times Square
Rockefeller Center
DIAMOND DISTRICT
Madison Ave
W 46th St
W 44th St
Tussauds New York
Holiday Inn New York City - Times Square by ...
MIDTOWN MANHATTAN
Grand Central
E 45th St
MANHATTAN DISTANCE
Times Sq - 42 St
5 Av
Bryant Park
B&H Photo Vide - Electronics and...
W 38th St
6th Ave
EUCLIDEAN DISTANCE
34 St-Penn Station
Moynihan Train at Penn Station
Macy's
8th Ave
W 30th St
W 29th St
W 33rd St
W 32nd St
Lexington Ave
Empire State Building
$|x_2 - x_1| + |y_2 - y_1|$


A co, gdy chcemy spojrzeć na oba punkty jednocześnie, zamiast znajdywać się w jednym z nich?
MANHATTAN DISTANCE
EUCLIDEAN DISTANCE
Square
Rockefeller Center
DIAMOND DISTRICT
W 46th St
W 44th St
Madison Ave
MIDTOWN MANHATTAN
Grand Central
E 45th St
5 Av
Bryant Park
Times Sq - 42 St
B&H Photo Vide
- Electronics and...
W 38th St
6th Ave
34 St-Penn Station
Moynihan Train
at Penn Station
Macy's
8th Ave
W 30th St
W 29th St
7th Ave
W 33rd St
W 32nd St
Lexington Ave
Empire State Building


A co, gdy chcemy spojrzeć na oba punkty jednocześnie, zamiast znajdywać się w jednym z nich?
MANHATTAN
EUCLIDEAN
COSINE DISTANCE
Square
Rockefeller Center
DIAMOND DISTRICT
W 46th St
W 44th St
Madison Ave
MIDTOWN MANHATTAN
Grand Central
E 45th St
5 Av
Bryant Park
6th Ave
Times Sq - 42 St
B&H Photo Video - Electronics and...
W 38th St
34 St-Penn Station
Macy's
8th Ave
W 30th St
W 29th St
7th Ave
W 33rd St
W 32nd St
Lexington Ave
Empire State Building



$$\cos \alpha = \frac{\sum_{i=1}^{n_s} x_i y_i}{\sqrt{\left(\sum_{i=1}^{n_s} x_i^2\right)} \sqrt{\left(\sum_{i=1}^{n_s} y_i^2\right)}},$$

$$\text{where} \quad x = z(T) \text{ and } y = z(T_1)$$

$$\text{and} \quad z(T) = \frac{f_s(T) - \mu_s}{\sigma_s}$$

Dobrze, ale jak to przełożyć na badania tekstów, literatury?

- frekwencję wystąpień każdego ze słów możemy zamienić na **wektory**
- wektory słów umieszczamy w **wielowymiarowej przestrzeni**
- przestrzeń ma tyle wymiarów, ile mamy wektorów słów dla danego tekstu
- między wektorami tworzą się **kąty**, których miary możemy analizować
- w obrębie tekstu wykonujemy dokładnie te same czynności, co przed chwilą na mapie Nowego Jorku

	Agnes Grey	Pride and prejudice	Jane Eyre	David Copperfield	The Mill on the Floss	Tom Jones
the	2511	4330	7835	13693	8690	16690
and	2733	3577	6618	12275	6182	8652
to	2366	4136	5152	10456	6082	11425
of	1602	3609	4359	8683	5042	10467
I	2204	2064	7165	13185	2760	6382
a	1296	1948	4467	7879	4806	6785
in	911	1866	2762	6218	3101	5680
that	776	1577	1655	5233	2946	4037
he	659	1338	1902	3526	2289	5034
was	1000	1847	2525	5314	3045	3997
it	795	1532	2403	4749	2401	3343

Co nam mówi ta tabelka?

	Agnes Grey	Pride and prejudice	Jane Eyre	David Copperfield	The Mill on the Floss	Tom Jones
the	2511	4330	7835	13693	8690	16690
and	2733	3577	6618	12275	6182	8652
to	2366	4136	5152	10456	6082	11425
of	1602	3609	4359	8683	5042	10467
I	2204	2064	7165	13185	2760	6382
a	1296	1948	4467	7879	4806	6785
in	911	1866	2762	6218	3101	5680
that	776	1577	1655	5233	2946	4037
he	659	1338	1902	3526	2289	5034
was	1000	1847	2525	5314	3045	3997
it	795	1532	2403	4749	2401	3343

Co nam mówi ta tabelka?

- w sumie to niewiele

Co nam mówi ta tabelka?

- w sumie to niewiele
- może jedynie, że *Tom Jones* jest prawdopodobnie czterokrotnie dłuższą książką niż *Duma i uprzedzenie*

Co nam mówi ta tabelka?

- w sumie to niewiele
- może jedynie, że *Tom Jones* jest prawdopodobnie czterokrotnie dłuższą książką niż *Duma i uprzedzenie*
- albo że Fielding pisał dość mało zdań współrzędnie złożonych

	Agnes Grey	Pride and prejudice	Jane Eyre	David Copperfield	The Mill on the Floss	Tom Jones
Tenant...	0.81	1.07	0.88	0.92	0.98	1.16
Emma	1.12	0.78	1.28	1.15	1.2	1.25
Sense and sensibility	1.14	0.69	1.24	1.16	1.25	1.13
The Professor	1.06	1.21	0.69	0.94	1	1.27
Villette	1.07	1.26	0.65	0.91	0.96	1.28
Bleak House	1.09	1.18	0.92	0.55	0.87	1.21
Hard Times	1.16	1.25	0.96	0.65	0.91	1.26
Wuthering Heights	1.13	1.31	0.81	0.94	1.01	1.32
Middlemarch	1.01	1.1	0.99	0.87	0.65	1.17
Adam Bede	1.2	1.37	0.95	0.9	0.66	1.42
Joseph Andrews	1.15	1.19	1.24	1.18	1.29	0.64

Co nam mówi ta tabelka?

- w sumie to niewiele

	Agnes Grey	Pride and prejudice	Jane Eyre	David Copperfield	The Mill on the Floss	Tom Jones
Tenant...	0.81	1.07	0.88	0.92	0.98	1.16
Emma	1.12	0.78	1.28	1.15	1.2	1.25
Sense and sensibility	1.14	0.69	1.24	1.16	1.25	1.13
The Professor	1.06	1.21	0.69	0.94	1	1.27
Villette	1.07	1.26	0.65	0.91	0.96	1.28
Bleak House	1.09	1.18	0.92	0.55	0.87	1.21
Hard Times	1.16	1.25	0.96	0.65	0.91	1.26
Wuthering Heights	1.13	1.31	0.81	0.94	1.01	1.32
Middlemarch	1.01	1.1	0.99	0.87	0.65	1.17
Adam Bede	1.2	1.37	0.95	0.9	0.66	1.42
Joseph Andrews	1.15	1.19	1.24	1.18	1.29	0.64

Co nam mówi ta tabelka?

- w sumie to już wiele

Co nam mówi ta tabelka?

- w sumie to już wiele
- możemy wyznaczyć, które teksty są do siebie podobne stylistycznie i najprawdopodobniej zostały napisane przez tę samą osobę

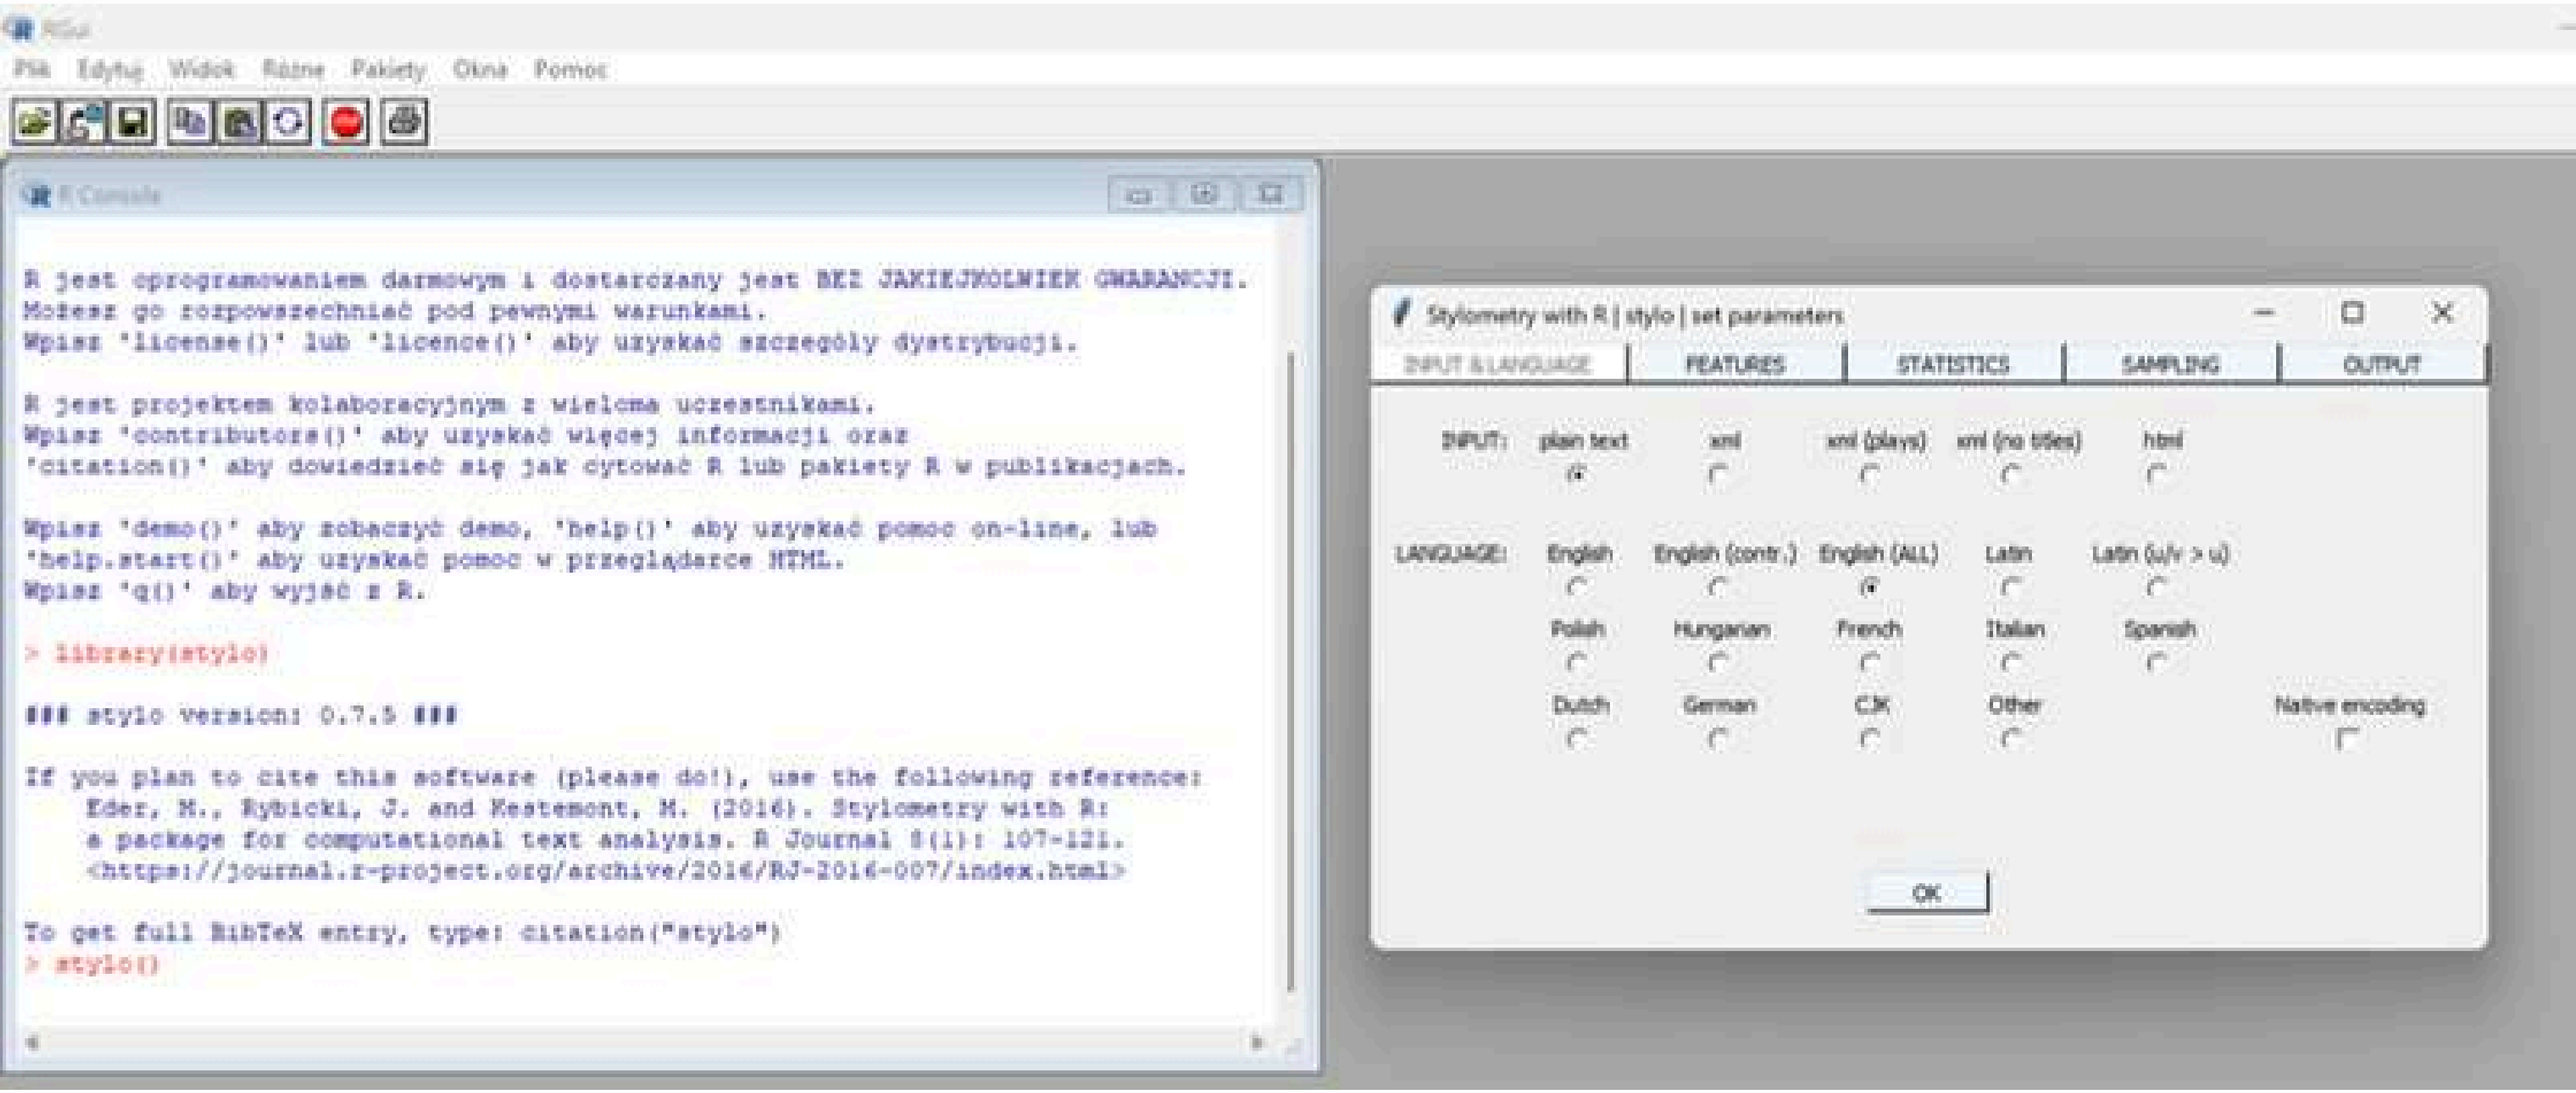
Co nam mówi ta tabelka?

- w sumie to już wiele
- możemy wyznaczyć, które teksty są do siebie podobne stylistycznie i najprawdopodobniej zostały napisane przez tę samą osobę
- możemy ustalić relacje rodzinne między autorami, którzy są spokrewnieni (z czego może wynikać podobieństwo stylistyczne np. sióstr Brontë?)

Co nam mówi ta tabelka?

- w sumie to już wiele
- możemy wyznaczyć, które teksty są do siebie podobne stylistycznie i najprawdopodobniej zostały napisane przez tę samą osobę
- możemy ustalić relacje rodzinne między autorami, którzy są spokrewnieni (z czego może wynikać podobieństwo stylistyczne np. sióstr Brontë?)
- możemy ustalić podobieństwo gatunkowe, które jest mniej wyraźne niż sygnał autorski, ale jest dalej widoczne

	Agnes Grey	Pride and prejudice	Jane Eyre	David Copperfield	The Mill on the Floss	Tom Jones
Tenant...	0.81	1.07	0.88	0.92	0.98	1.16
Emma	1.12	0.78	1.28	1.15	1.2	1.25
Sense and sensibility	1.14	0.69	1.24	1.16	1.25	1.13
The Professor	1.06	1.21	0.69	0.94	1	1.27
Villette	1.07	1.26	0.65	0.91	0.96	1.28
Bleak House	1.09	1.18	0.92	0.55	0.87	1.21
Hard Times	1.16	1.25	0.96	0.65	0.91	1.26
Wuthering Heights	1.13	1.31	0.81	0.94	1.01	1.32
Middlemarch	1.01	1.1	0.99	0.87	0.65	1.17
Adam Bede	1.2	1.37	0.95	0.9	0.66	1.42
Joseph Andrews	1.15	1.19	1.24	1.18	1.29	0.64


RGui
Plik Edytuj Widok Różne Pakiety Okna Pomoc
R Console
R jest oprogramowaniem darmowym i dostarczany jest BEZ JAKIEJKOLWIEK GWARANCJI.
Możesz go rozpowszechniać pod pewnymi warunkami.
Wpisz 'license()' lub 'licence()' aby uzyskać szczegóły dystrybucji.
R jest projektem kolaboracyjnym z wieloma uczestnikami.
Wpisz 'contributors()' aby uzyskać więcej informacji oraz
'citation()' aby dowiedzieć się jak cytować R lub pakiety R w publikacjach.
Wpisz 'demo()' aby zobaczyć demo, 'help()' aby uzyskać pomoc on-line, lub
'help.start()' aby uzyskać pomoc w przeglądarce HTML.
Wpisz 'q()' aby wyjść z R.
> library(stylo)
stylo version: 0.7.5
If you plan to cite this software (please do!), use the following reference:
Eder, M., Rybicki, J. and Kestemont, M. (2016). Stylometry with R:
a package for computational text analysis. R Journal 8(1): 107-121.
<http://journal.r-project.org/archive/2016/RJ-2016-007/index.html>
To get full BibTeX entry, type: citation("stylo")
> stylo()
Stylometry with R | stylo | set parameters
INPUT & LANGUAGE
FEATURES
STATISTICS
SAMPLING
OUTPUT
INPUT:
plain text
xml
xml (plays)
xml (no tbes)
html
LANGUAGE:
English
English (contr.)
English (ALL)
Latin
Latin (u/v > u)
Polish
Hungarian
French
Italian
Spanish
Dutch
German
CJK
Other
Native encoding
OK

Ważne informacje, pojęcia przed wykonaniem analiz

- pracujemy na „surowych” plikach (***raw files***), najlepiej w formacie **txt**
- sprawdzamy sposób kodowania plików, żeby się upewnić, że analiza przebiegnie poprawnie - sprawdzamy, czy jest format **UTF-8**
- pracujemy na **niezlematyzowanych słowach**, ale możemy wykonywać analizę **n-gramów** poszczególnych znaków (przydatne, gdyby ktoś chciał badać np. chiński)

Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?

Formaty tekstowe plików:

TXT	**RTF**	**DOC/DOCX**	**ODT**	**XML**	**CSS**	**HTML**	**WPS**

Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?

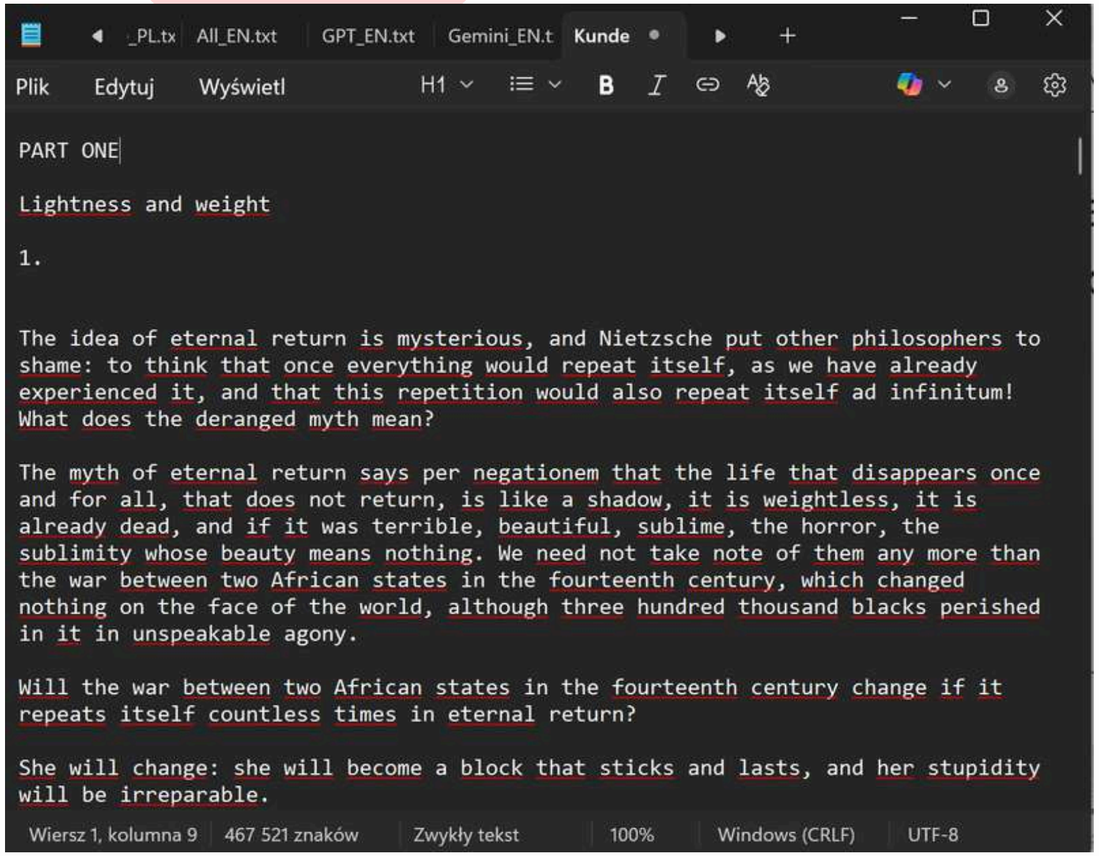
Formaty tekstowe plików:

TXT	**RTF**	**DOC/DOCX**	**ODT**	**XML**	**CSS**	**HTML**	**WPS**

Formaty akceptowane przez *stylo*:

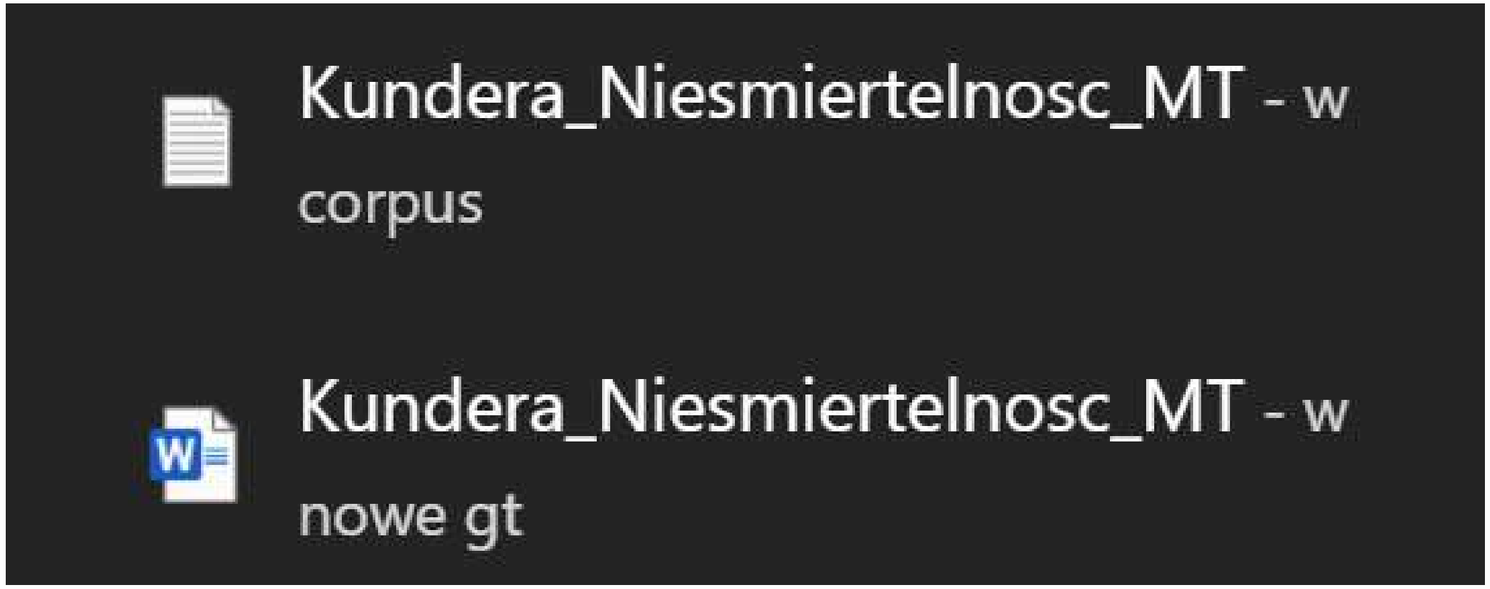


Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?





Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?



Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?

Nazwa	Data modyfikacji	Typ	Rozmiar
Kundera_Niesmiertelnosc_MT	09.07.2025 08:51	Dokument programu Microsoft Word	345 KB
Lackberg_Kaznodzieja_MT	09.07.2025 08:52	Dokument programu Microsoft Word	436 KB
Lackberg_SrebrneSkrzydla_MT	09.07.2025 08:52	Dokument programu Microsoft Word	312 KB
Lackberg_ZlotaKlatka_MT	09.07.2025 08:52	Dokument programu Microsoft Word	431 KB
Lagerlof_CudownaPodroz_MT	09.07.2025 08:52	Dokument programu Microsoft Word	110 KB
Lagerlof_GostaBerling_MT	09.07.2025 08:53	Dokument programu Microsoft Word	498 KB
Lagerlof_TetniaceSerce_MT	09.07.2025 08:53	Dokument programu Microsoft Word	216 KB
Link_Oszukana_MT	09.07.2025 08:53	Dokument programu Microsoft Word	620 KB
Link_Poszukiwanie_MT	09.07.2025 08:53	Dokument programu Microsoft Word	691 KB
Lispector_GodzinaGwiazdy_MT	09.07.2025 08:53	Dokument programu Microsoft Word	116 KB
Lispector_PasjaWedlugGH_MT	09.07.2025 08:54	Dokument programu Microsoft Word	148 KB
Lispector_WPoblizuDzikiegoSerca_MT	09.07.2025 08:54	Dokument programu Microsoft Word	180 KB
Llosa_BurzliweCzasy_MT	09.07.2025 08:54	Dokument programu Microsoft Word	303 KB
Llosa_CiotkaJuliaISkryba_MT	09.07.2025 08:54	Dokument programu Microsoft Word	407 KB
Llosa_DzielnicaWystepku_MT	09.07.2025 08:54	Dokument programu Microsoft Word	246 KB
Llosa_SzelmostwaNiegrzecznejDziewczynki_MT	09.07.2025 08:55	Dokument programu Microsoft Word	366 KB
Llosa_ZielonyDom_MT	09.07.2025 08:55	Dokument programu Microsoft Word	450 KB
Mankell_Chinczyk_MT	09.07.2025 08:55	Dokument programu Microsoft Word	596 KB
Mankell_FalszywyTrop_MT	09.07.2025 08:56	Dokument programu Microsoft Word	566 KB
Mankell_MordercaBezTwarzy_MT	09.07.2025 08:56	Dokument programu Microsoft Word	369 KB

Nazwa	Data modyfikacji	Typ	Rozmiar
Koch_DomLetniZBasenem_FR_HT	08.07.2025 19:29	Dokument tekstowy	680 KB
Koch_Kolacja_FR_HT	08.07.2025 19:04	Dokument tekstowy	490 KB
Kundera_Niesmiertelnosc_FR_HT	08.07.2025 19:16	Dokument tekstowy	689 KB
Kundera_Zart_FR_HT	08.07.2025 18:55	Dokument tekstowy	703 KB
Lackberg_Kaznodzieja_FR_HT	08.07.2025 19:10	Dokument tekstowy	789 KB
Lackberg_SrebrneSkrzydla_FR_HT	08.07.2025 18:46	Dokument tekstowy	471 KB
Lackberg_ZlotaKlatka_FR_HT	08.07.2025 18:48	Dokument tekstowy	587 KB
Lagerlof_CudownaPodroz_FR_HT	08.07.2025 19:07	Dokument tekstowy	1 230 KB
Lagerlof_GostaBerling_FR_HT	08.07.2025 18:53	Dokument tekstowy	443 KB
Lagerlof_TetniaceSerce_FR_HT	08.07.2025 19:12	Dokument tekstowy	371 KB
Link_Oszukana_FR_HT	08.07.2025 18:47	Dokument tekstowy	772 KB
Link_Poszukiwanie_FR_HT	08.07.2025 19:13	Dokument tekstowy	777 KB
Lispector_PasjaWedlugGH_GodzinaGwiazdy_FR_...	08.07.2025 19:17	Dokument tekstowy	515 KB
Lispector_WPoblizuDzikiegoSerca_FR_HT	08.07.2025 19:23	Dokument tekstowy	17 KB
Llosa_BurzliweCzasy_FR_HT	08.07.2025 19:26	Dokument tekstowy	624 KB
Llosa_CiotkaJuliaISkryba_FR_HT	08.07.2025 18:56	Dokument tekstowy	828 KB
Llosa_DzielnicaWystepku_FR_HT	08.07.2025 19:30	Dokument tekstowy	471 KB
Llosa_SzelmostwaNiegrzecznejDziewczynki_FR_...	08.07.2025 19:27	Dokument tekstowy	725 KB
Llosa_ZielonyDom_FR_HT	08.07.2025 18:54	Dokument tekstowy	1 034 KB
Mankell_Chinczyk_FR_HT	08.07.2025 19:02	Dokument tekstowy	918 KB

Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?



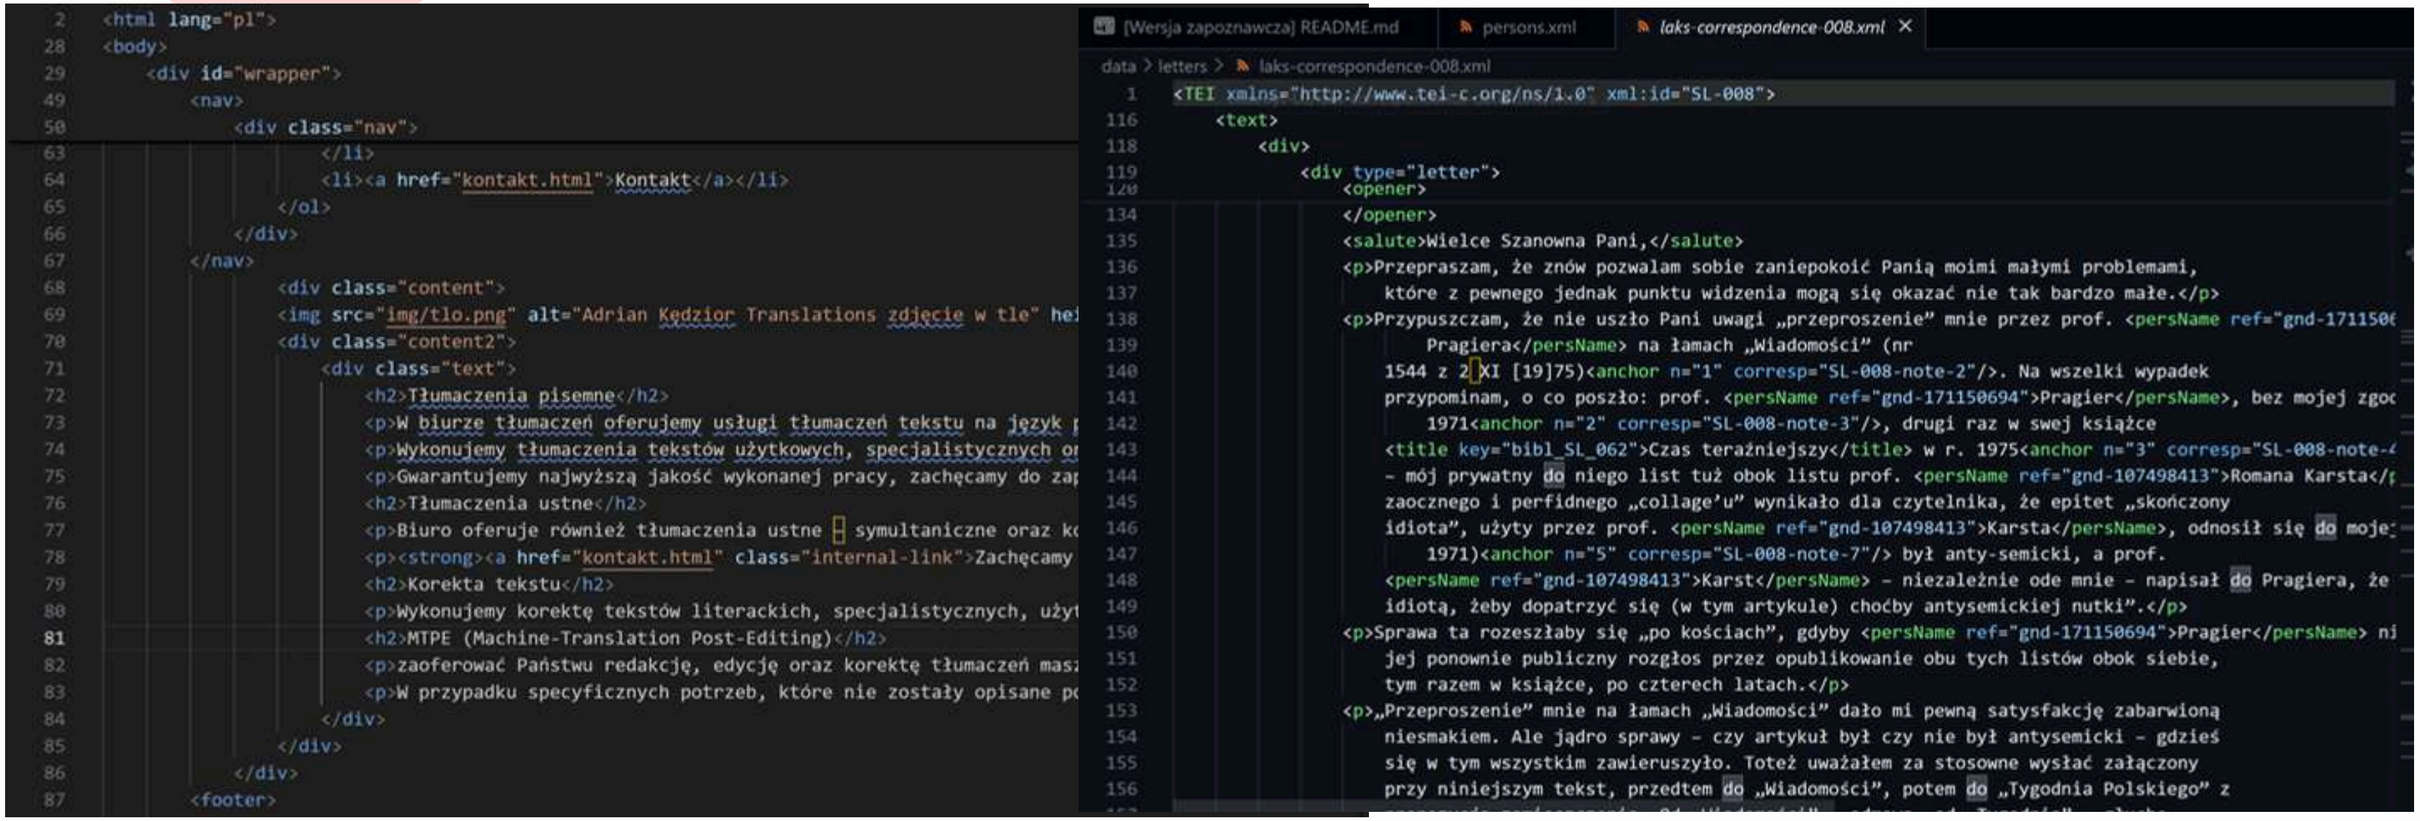


Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?

```
    Directory: C:\Users\aleks\Desktop\studia\doktorat\korpus\oryginały


Mode                 LastWriteTime         Length Name
----                 -------------         ------ ----
d-----         09.07.2025     09:26                nowe
-a----         05.12.2024     11:27         616931 Andric_MostNaDrinie.docx
-a----         04.12.2024     14:50        1195521 Andric_MostNaDrinie.txt
-a----         05.12.2024     11:58         330633 Blixen_PozegnanieZAfryka.docx
-a----         04.12.2024     14:49         702547 Blixen_PozegnanieZAfryka.txt
-a----         05.12.2024     12:38         534510 Bulhakov_MistrzIMalgorzata.docx
-a----         04.12.2024     15:06        1431645 Bulhakov_MistrzIMalgorzata.txt
-a----         05.12.2024     11:20         285199 Calvino_BaronDrzewolaz.docx
-a----         04.12.2024     17:47         536059 Calvino_BaronDrzewolaz.txt
-a----         05.12.2024     11:23         236376 Calvino_JesliZimowaNocaPodrozny.docx
-a----         04.12.2024     17:21         461636 Calvino_JesliZImowaNocaPodrozny.txt
-a----         05.12.2024     10:52         620366 Cortazar_GrawKlasy.docx
-a----         04.12.2024     14:50        1047278 Cortazar_GrawKlasy.txt
-a----         05.12.2024     12:37        1173200 Dostojewski_BraciaKaramazov.docx
-a----         04.12.2024     14:49        3281542 Dostojewski_BraciaKaramazov.txt
-a----         05.12.2024     13:27        1061760 Dostojewski_Idiota.docx
-a----         04.12.2024     17:48        2423300 Dostojewski_Idiota.txt
-a----         05.12.2024     12:33        1575729 Dostojewski_ZbrodniaIKara.docx
-a----         04.12.2024     14:49        4324305 Dostojewski_ZbrodniaIKara.txt
-a----         05.12.2024     11:25         624544 Eco_ImieRozy.docx
-a----         04.12.2024     17:21        1219346 Eco_ImieRozy.txt
-a----         04.12.2024     17:21        1428592 Eco_WagadloFoucaulta.txt
-a----         05.12.2024     11:26         236378 Eco_WahadloFoucaulta.docx
```

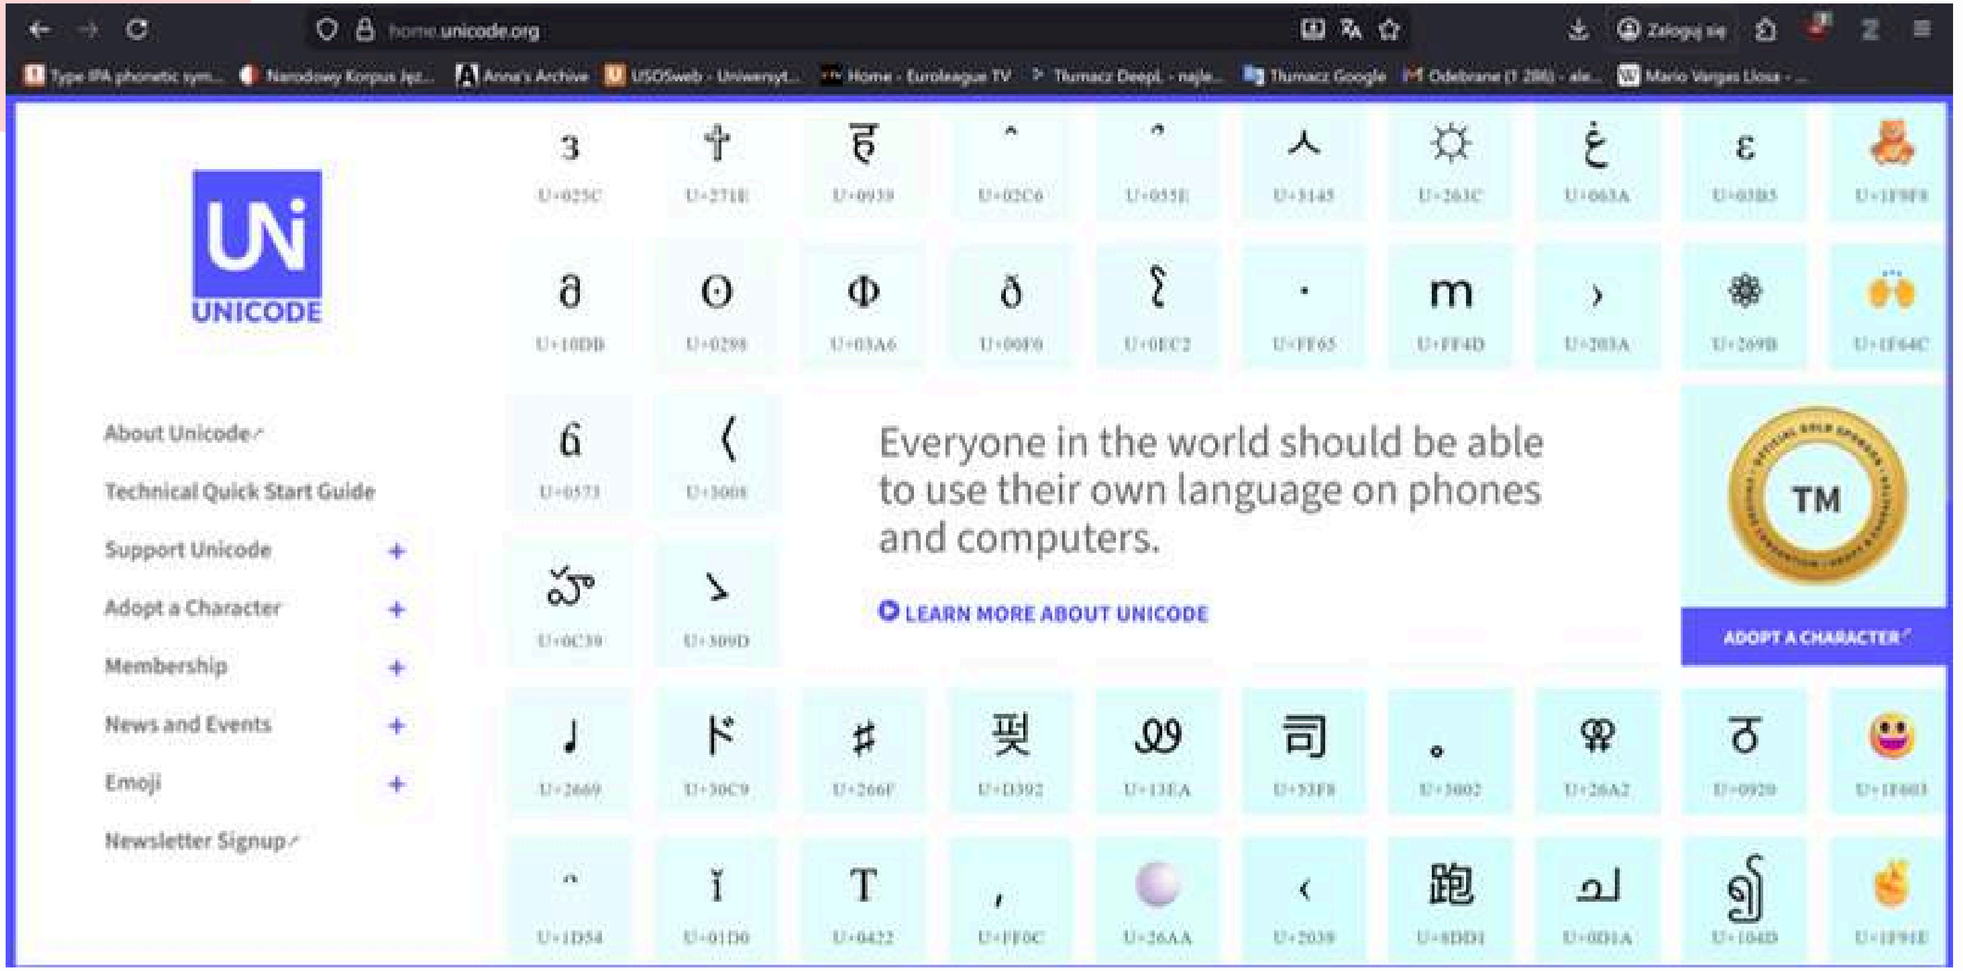
Jak dowiedzieć się w jakim formacie tekstowym zapisujemy plik?



Ważne informacje, pojęcia przed wykonaniem analiz

- ~~pracujemy na „surowych” plikach (***raw files***), najlepiej w formacie **txt**~~
- sprawdzamy sposób kodowania plików, żeby się upewnić, że analiza przebiegnie poprawnie - sprawdzamy, czy jest format **UTF-8**
- pracujemy na **niezlematyzowanych słowach**, ale możemy wykonywać analizę **n-gramów** poszczególnych znaków (przydatne, gdyby ktoś chciał badać np. chiński)

Co to UTF-8 i dlaczego jest ważne?



Co to UTF-8 i dlaczego jest ważne?

Do najpowszechniejszych metod bajtowego kodowania znaków należą:

- UTF-32/UCS-4
- UTF-16
- UTF-8.

Mniej popularnymi kodowaniami Unicode są:

- UTF-7
- UCS-2.

Istnieją również inne kodowania, stanowiące margines lub pozostające na etapie propozycji, na przykład:

- UTF-9 i UTF-18
- UTF-EBCDIC
- UTF-6
- UTF-5.

Co to UTF-8 i dlaczego jest ważne?

```
A Chinese character:      汉
its Unicode value:        U+6C49
convert 6C49 to binary:   01101100 01001001
```

Binary format of bytes in sequence

1st Byte	2nd Byte	3rd Byte	4th Byte	Number of Free Bits
0xxxxxxx				7
110xxxxx	10xxxxxx			(5+6)=11
1110xxxx	10xxxxxx	10xxxxxx		(4+6+6)=16
11110xxx	10xxxxxx	10xxxxxx	10xxxxxx	(3+6+6+6)=21

```
Maximum Expressible Unicode Value
007F hex (127)
07FF hex (2047)
FFFF hex (65535)
10FFFF hex (1,114,111)
```

Header	Place holder	Fill in our Binary	Result
1110	xxxx	0110	11100110
10	xxxxxx	110001	10110001
10	xxxxxx	001001	10001001

PREMIÃRE PARTIE

LUDVIK

Ainsi, aprÃ¨s bien des annÃ©es, je me retrouvais chez moi. Debout sur la grande place (quâ€™enfant, puis gamin, puis jeune homme, jâ€™avais mille fois traversÃ©e), je ne r
Des annÃ©es durant, rien ne mâ€™avait attirÃ© vers ma ville natale ; je me disais quâ€™elle mâ€™Ã©tait devenue indiffÃ©rente, et cela me paraissait naturel : depuis quinze
Une fois encore je parcourus dâ€™un Å“il narquois la place disgracieuse avant de lui tourner le dos pour prendre la rue de lâ€™hÃ´tel oÃ¹ ma chambre Ã©tait retenue pour le
Je mâ€™assis sur la chaise, le regard perdu vers les rideaux Ã©clairÃ©s en transparence, et je rÃ©flÃ©chis. Ã€ cet instant, des pas et des voix se firent entendre du corri
Je me levai, ma rÃ©solution Ã©tait prise ; je me lavai encore les mains dans le lavabo, les essuyai avec la serviette et quittai lâ€™hÃ´tel sans bien savoir dâ€™abord oÃ¹
Cet hÃ´pital est un ensemble de bÃ¢timents et de pavillons semÃ©s Ã§Ã et lÃ sur un vaste espace de jardins ; je pÃ©nÃ©trai dans la petite guÃ©rite qui jouxte le portail
Je lui expliquai que jâ€™Ã©tais arrivÃ© moins dâ€™une heure plus tÃ´t pour une affaire sans importance qui me retiendrait ici environ deux jours, et il manifesta tout de s
Â« Je cours les filles, rÃ©pondis-je. Â» Ce nâ€™est pas pour des femmes, câ€™est pour moi quâ€™il me faut ma libertÃ© Ã¢, dit-il, et il ajouta : Â« Ã‰coutez, venez un mo
Sortis de lâ€™enceinte de lâ€™hÃ´pital, nous parvÃ®nmes bientÃ´t Ã un groupe dâ€™immeubles neufs qui, lâ€™un Ã cÃ´tÃ© de lâ€™autre, jaillissaient sans harmonie dâ€™un so
Je fis Ã Kostka lâ€™Ã©loge de sa chambre et lui demandai comment Ã©tait sa salle de bains. Â« Rien de luxueux Ã¢, dit-il, content de lâ€™intÃ©rÃªt que je marquais, et il
Ma question lâ€™Ã©tonna, mais sur-le-champ (comme sâ€™il craignait que je ne le soupÃ§onne de manquer dâ€™empressement) il me dit : Â« Bien volontiers, il est Ã vous Â» E
AprÃ¨s quoi nous prÃ®mes place autour de la petite table (Kostka avait prÃ©parÃ© du cafÃ©) et bavardÃ®mes un moment (assis sur le divan, jâ€™en constatais avec plaisir la
Kostka exprima en partant le vÅ“u que son studio me procure Â« vraiment quelque chose de beau Â». Â« Oui, lui dis-je, il va me permettre dâ€™effectuer une belle destructi
Nous nous retrouvions lÃ oÃ¹ nous nous Ã©tions sÃ©parÃ©s la derniÃ¨re fois (peut-Ãªtre quelque neuf ans plus tÃ´t) ; notre diffÃ©rend revÃªtait Ã prÃ©sent une allure mÃ©
Tandis que jâ€™accompagnais Kostka pour regagner lâ€™hÃ´pital Ã lâ€™autre bout de la ville, je jouais avec les clÃ©s au fond de ma poche et je me sentais bien au cÅ“ur d
Je ne dÃ©clinai pas les bons offices de Kostka et me laissai emmener dans un petit salon oÃ¹ devant trois glaces Ã©taient plantÃ©s trois grands fauteuils pivotants dont de
Je maintins mes yeux au plafond mÃªme aprÃ¨s avoir senti sur mon cou les doigts de la coiffeuse qui glissaient sous le col de ma chemise le bord dâ€™un linge blanc. Puis l
Puis les ciseaux parcoururent et lâ€™entourÃ¨rent la coiffeuse sâ€™Ã©loigna afin cette fois de vraiment saisir la pointe [illegible]

PREMIÈRE PARTIE

LUDVIK

Ainsi, après bien des années, je me retrouvais chez moi. Debout sur la grande place (qu'enfant, puis gamin, puis jeune homme, j'avais mille fois traversée), je ne ressenta
Des années durant, rien ne m'avait attiré vers ma ville natale ; je me disais qu'elle m'était devenue indifférente, et cela me paraissait naturel : depuis quinze ans déjà
Une fois encore je parcourus d'un œil narquois la place disgracieuse avant de lui tourner le dos pour prendre la rue de l'hôtel où ma chambre était retenue pour la nuit. I
Je m'assis sur la chaise, le regard perdu vers les rideaux éclairés en transparence, et je réfléchis. À cet instant, des pas et des voix se firent entendre du corridor ; c
Je me levai, ma résolution était prise ; je me lavai encore les mains dans le lavabo, les essuyai avec la serviette et quittai l'hôtel sans bien savoir d'abord où j'irais
Cet hôpital est un ensemble de bâtiments et de pavillons semés çà et là sur un vaste espace de jardins ; je pénétrai dans la petite guérite qui jouxte le portail et je pri
Je lui expliquai que j'étais arrivé moins d'une heure plus tôt pour une affaire sans importance qui me retiendrait ici environ deux jours, et il manifesta tout de suite ur
— Je cours les filles, répondis-je. — Ce n'est pas pour des femmes, c'est pour moi qu'il me faut ma liberté », dit-il, et il ajouta : « Écoutez, venez un moment chez moi,
Sortis de l'enceinte de l'hôpital, nous parvînmes bientôt à un groupe d'immeubles neufs qui, l'un à côté de l'autre, jaillissaient sans harmonie d'un sol poussiéreux non e
Je fis à Kostka l'éloge de sa chambre et lui demandai comment était sa salle de bains. « Rien de luxueux », dit-il, content de l'intérêt que je marquais, et il me fit pass
Ma question l'étonna, mais sur-le-champ (comme s'il craignait que je ne le soupçonne de manquer d'empressement) il me dit : « Bien volontiers, il est à vous » Et de pouvoi
Après quoi nous prîmes place autour de la petite table (Kostka avait préparé du café) et bavardâmes un moment (assis sur le divan, j'en constatais avec plaisir la fermeté,
Kostka exprima en partant le vœu que son studio me procure « vraiment quelque chose de beau ». « Oui, lui dis-je, il va me permettre d'effectuer une belle destruction. — \
Nous nous retrouvions là où nous nous étions séparés la dernière fois (peut-être quelque neuf ans plus tôt) ; notre différend revêtait à présent une allure métaphorique pa
Tandis que j'accompagnais Kostka pour regagner l'hôpital à l'autre bout de la ville, je jouais avec les clés au fond de ma poche et je me sentais bien au côté de l'ami de
Je ne déclinai pas les bons offices de Kostka et me laissai emmener dans un petit salon où devant trois glaces étaient plantés trois grands fauteuils pivotants dont deux é
Je maintins mes yeux au plafond même après avoir senti sur mon cou les doigts de la coiffeuse qui glissaient sous le col de ma [illegible] le bord d'un linge blanc. Puis la co
Puis, les ciseaux cessèrent et j'entendis la coiffeuse s'écarter afin, cette fois, de vraiment saisir la serviette et la mettre à ce moment-là les paroles [illegible]

Ważne informacje, pojęcia przed wykonaniem analiz

- ~~pracujemy na „surowych” plikach (***raw files***), najlepiej w formacie **txt**~~
- ~~sprawdzamy sposób kodowania plików, żeby się upewnić, że analiza przebiegnie poprawnie - sprawdzamy, czy jest format **UTF-8**~~
- pracujemy na **niezlematyzowanych słowach**, ale możemy wykonywać analizę **n-gramów** poszczególnych znaków (przydatne, gdyby ktoś chciał badać np. chiński)

Czym jest lematyzacja?

Wszyscy mamy bardzo fajne mamy.

Czym jest lematyzacja?

Wszyscy mamy bardzo fajne mamy.

Wszyscy mieć bardzo fajny mama.

Co to n-gramy?

To be or not to be.

2-gramy

Co to n-gramy?

To be or not to be.

2-gramy

to-o_-_b-be-e_-_o-or-r_-_n-no-ot-t_-_t-to-o_-_b-be-e.

Co to n-gramy?

To be or not to be.

3-gramy

to_-o_b-_be-be_-e_o-_or-or_-r_n-_no-not-ot_-t_t-_to-to_-o_b-_be-be.

Co to n-gramy?

To be or not to be.

2-gramy słów

to be-be or-or not-not to-to be

Co to n-gramy?

To be or not to be.

3-gramy słów

to be or-be or not-or not to-not to be

Ważne informacje, pojęcia przed wykonaniem analiz

- ~~pracujemy na „surowych” plikach (***raw files***), najlepiej w formacie **txt**~~
- ~~sprawdzamy sposób kodowania plików, żeby się upewnić, że analiza przebiegnie poprawnie - sprawdzamy, czy jest format **UTF-8**~~
- ~~pracujemy na **niezlematyzowanych słowach**, ale możemy wykonywać analizę **n-gramów** poszczególnych znaków (przydatne, gdyby ktoś chciał badać np. chiński)~~

Do zobaczenia za tydzień!

